


2026 届硕士专业学位研究生学位论文

分 类 号: _____

学校代码: _____ 10269

密 级: _____

学 号: _____ 51265901080



華東師範大學

East China Normal University

硕士学位论文

MASTER'S DISSERTATION

论文题目: _____
基于动态路由与多模态提示
的一体化引导式图像超分

院 系: _____ 计算机科学与技术学院

专业学位类别: _____ 电子信息

专业学位领域: _____ 计算机技术

学 位 申 请 人: _____ 王君

指 导 教 师: _____ 方发明 教授

2026 年 04 月 22 日

Dissertation for Master's Degree (Professional) in 2026

University Code: 10269

Student ID: 51265901080

EAST CHINA NORMAL UNIVERSITY

**Title: All-in-One Guided Image Super-
Resolution Based on Dynamic Routing
and Multi-modal Prompting**

Department / School:	<u>School of Computer Science and Technology</u>
Category:	<u>Computer Science</u>
Field:	<u>Image Processing</u>
Candidate:	<u>Jun Wang</u>
Supervisor:	<u>Prof. Faming Fang</u>

Apr 22, 2026

华东师范大学学位论文原创性声明

郑重声明：本人呈交的学位论文《基于动态路由与多模态提示的一体化引导式图像超分》，是在华东师范大学攻读硕士/博士（请勾选）学位期间，在导师的指导下进行的研究工作及取得的研究成果。除文中已经注明引用的内容外，本论文不包含其他个人已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中作了明确说明并表示谢意。

作者签名：_____ 日 期：_____ 年 月 日

华东师范大学学位论文著作权使用声明

《基于动态路由与多模态提示的一体化引导式图像超分》系本人在华东师范大学攻读学位期间在导师指导下完成的硕士/博士（请勾选）学位论文，本论文的著作权归本人所有。本人同意华东师范大学根据相关规定保留和使用此学位论文，并向主管部门和学校指定的相关机构送交学位论文的印刷版和电子版；允许学位论文进入华东师范大学图书馆及数据库被查阅、借阅；同意学校将学位论文加入全国博士、硕士学位论文共建单位数据库进行检索，将学位论文的标题和摘要汇编出版，采用影印、缩印或者其它方式合理复制学位论文。

本学位论文属于（请勾选）

- ☐ 1. 经华东师范大学相关部门审查核定的“内部”或“涉密”学位论文*，
于_____年_____月_____日解密，解密后适用上述授权。
- ☐ 2. 不保密，适用上述授权。

导师签名：_____ 作者签名：_____
日 期：_____ 年 月 日

* “涉密”学位论文应是已经华东师范大学学位管理办公室或保密委员会审定过的学位论文（需附获批的《华东师范大学研究生申请学位论文“涉密”审批表》方为有效），未经上述部门审定的学位论文均为公开学位论文。此声明栏不填写的，默认为公开学位论文，均适用上述授权）。

王君 硕士学位论文答辩委员会成员名单

姓名	职称	单位	备注
王妍	青年研究院	华东师范大学	主席
刘丛	副教授	上海理工大学	委员
袁怡婷	高级工程师	思爱普（中国）有限公司	委员

摘 要

引导式图像超分旨在利用高分辨率的辅助图像（如全色图像、RGB 图像等）来提升低分辨率目标图像的空间分辨率，被广泛应用于遥感监测、医学成像及深度估计等领域。然而，现有的引导超分方法主要针对单一领域的特定任务设计，由于不同任务间存在巨大的模态差异和成像机理鸿沟，导致模型在跨任务场景下泛化能力不足，且面临着任务间相互干扰的挑战。为打破“一任务一模型”的传统范式，实现多模态任务的高效协同与通用重建，深度挖掘不同任务之间的潜在关联，本文基于提示学习与混合专家机制，提出了层层递进的两种一体化引导式图像超分方法，具体如下：

（1）针对一体化引导式图像超分任务中存在的参数干扰与负迁移问题，提出了一种基于视觉感知动态路由的图像重建方法（VP-Net）。该方法创新性地引入混合专家（MoE）架构，利用引导图像的纹理、边缘等底层视觉特征作为隐式路由信号，动态激活特定任务的专家网络。这种基于视觉特征的“物理隔离”策略，有效缓解了多任务间的优化冲突，在不显著增加计算成本的前提下实现了对不同模态数据的差异化处理。

（2）针对纯视觉感知路由机制存在的语义缺失问题，提出了一种融合多模态语义提示的图像重建方法（MAG-Net）。该方法在动态路由架构的基础上引入文本语义先验，设计了多模态提示生成模块（MPGM），利用预训练视觉-语言模型将任务描述转化为高维语义锚点，并注入到路由决策过程中。通过视觉感知+语义引导的双重驱动机制，该方法消除了视觉特征的歧义性，实现了像素级与任务级的精细化调控，显著提升了模型在全色锐化、深度图超分及磁共振重建等任务上的性能。

（3）针对现有先进深度学习模型多以代码脚本形式存在、使用门槛高且难以直接服务于垂直领域专家的问题，设计并实现了一体化引导式图像超分演示系统。该系统基于 B/S 架构，集成了本文提出的核心算法模型，通过封装复杂的模型推理与环境配置过程，为医学、遥感及测绘等领域的非技术用户提供了一个零代码、可视化的高质量图像增强平台，有效缩短了从算法研究到实际应用的距离。

关键词：引导式图像超分，一体化模型，动态路由，多模态融合

Abstract

Guided image super-resolution aims to enhance the spatial resolution of low-resolution target images using high-resolution auxiliary images (such as panchromatic images, RGB images, etc.), and is widely used in remote sensing monitoring, medical imaging, and depth estimation. However, existing guided super-resolution methods are mainly designed for single specific tasks. Due to the huge modal differences and imaging mechanism gaps between different tasks, models lack generalization capability in cross-task scenarios and face the challenge of mutual interference between tasks. To break the traditional paradigm of “one model for one task” and achieve efficient collaboration and general reconstruction for multi-modal tasks, this thesis proposes two progressive All-in-One guided image super-resolution methods based on prompt learning and Mixture-of-Experts (MoE) mechanism, specifically as follows:

(1) Addressing the problems of parameter interference and negative transfer in All-in-One guided image super-resolution tasks, a dynamic routing image reconstruction method based on visual perception (VP-Net) is proposed. This method innovatively introduces the Mixture-of-Experts (MoE) architecture, using low-level visual features such as textures and edges of the guidance image as implicit routing signals to dynamically activate task-specific expert networks. This “physical isolation” strategy based on visual features effectively alleviates optimization conflicts between multi-tasks and achieves differentiated processing of multi-modal data without significantly increasing computational costs.

(2) Addressing the problems of “visual ambiguity” and “semantic absence” existing in pure visual perception routing mechanisms, an image reconstruction method integrating multi-modal semantic prompts (MAG-Net) is proposed. Based on the dynamic routing architecture, this method introduces textual semantic priors and designs a Multi-modal Prompt Generation Module (MPGM), which utilizes a pre-trained vision-language model to transform task descriptions into high-dimensional semantic anchors and injects them into the routing decision process. Through the dual-

drive mechanism of visual perception + semantic guidance, this method eliminates the ambiguity of visual features, achieves refined control at both pixel and task levels, and significantly improves the model's performance on tasks such as pansharpening, depth map super-resolution, and MRI reconstruction.

(3) Addressing the problem that existing advanced deep learning models mostly exist in the form of code scripts, have high barriers to use, and are difficult to directly serve experts in vertical fields, an All-in-One guided image super-resolution demonstration system is designed and implemented. Based on the B/S architecture, this system integrates the core algorithm models proposed in this thesis. By encapsulating complex model inference and environment configuration processes, it provides a zero-code, visual, and high-quality image enhancement platform for non-technical users in fields such as medicine, remote sensing, and surveying, effectively shortening the distance from algorithm research to practical application.

Keywords: *Guided Image Super-Resolution, All-in-One Model, Dynamic Routing, Multi-modal Fusion*

目 录

摘要	I
Abstract	III
插图目录	IX
表格目录	XI
第一章 绪论	1
1.1 研究背景与意义	1
1.2 国内外研究现状	2
1.2.1 引导式图像超分方法	2
传统方法	2
基于深度学习的方法	3
1.2.2 一体化图像恢复研究现状	4
基于提示引导的方法	5
基于对比学习的方法	6
1.3 本文主要工作	7
1.4 论文组织结构	7
第二章 相关理论与技术基础	10
2.1 引导式图像超分基础	10
2.1.1 问题数学定义	10
全色锐化	10
深度图超分	11
磁共振图像超分	11
2.1.2 引导式图像超分任务评价指标	12
峰值信噪比 (PSNR)	12
结构相似度 (SSIM)	12
均方根误差 (RMSE)	12
光谱角映射 (SAM)	13
综合相对全局误差 (ERGAS)	13
2.2 一体化图像恢复相关基础	13
2.2.1 Transformer 与 ViT	14

2.2.2 Restormer 及核心组件	15
多头转置注意力机制	15
门控前馈网络	15
2.2.3 混合专家系统基本原理	16
Top-K 稀疏路由	17
2.3 多模态预训练模型与提示学习	18
2.3.1 视觉-语言大模型	18
2.3.2 提示学习	18
2.4 本章小结	19
第三章 面向一体化任务的视觉感知与动态路由 GISR 方法	20
3.1 引言	20
3.2 算法概述	22
3.2.1 整体网络架构	22
3.2.2 基于视觉感知的动态路由模块	24
3.2.3 损失函数	27
3.3 实验设置	28
3.3.1 数据集	28
3.3.2 评测指标	29
3.3.3 实验细节	30
3.4 实验结果	30
3.4.1 对比实验	31
3.4.2 消融实验	33
VPRM 有效性消融分析	33
VPRM 位置消融分析	33
3.4.3 动态路由机制的可视化分析	34
浅层 (L1) 的显著分化	34
深层 (L4) 的趋同性	35
任务间的独特性与重叠	35
3.5 本章小结	35
第四章 融合多模态语义提示的一体化 GISR 方法	37

4.1	引言	37
4.2	算法概述	38
4.2.1	整体网络架构	38
4.2.2	多模态提示生成模块	40
	视觉-语言特征提取	40
	跨模态特征调制	41
	基于字典的提示重构	41
4.2.3	融合多模态提示的动态路由模块	41
4.3	实验设置	43
4.3.1	数据集与评测指标	43
4.3.2	实验细节	43
4.4	实验结果	44
4.4.1	对比实验	44
	一体化方法对比	44
	单任务方法对比	47
4.4.2	消融实验	51
	MPGM 与 MGRM 的有效性	51
	任务组合消融	52
	多模态提示消融	53
4.4.3	任务提示的可视化	53
4.5	本章小结	55
第五章	一体化引导式图像超分系统	57
5.1	引言	57
5.2	需求分析	57
5.2.1	功能性需求	57
	面向多领域任务的场景化配置	58
	交互式可视化与对比分析	58
	工程化批量处理	58
	全流程历史追溯	58
	多用户隔离与数据安全	59

5.2.2 非功能性需求	59
极简操作与低学习成本	59
高响应与实时反馈	59
兼容性与易部署	59
5.3 系统设计与实现	60
5.3.1 总体架构	60
展示层	60
服务层	60
算法层	60
数据层	60
5.3.2 功能模块设计与实现	61
用户认证与权限管理模块	61
交互式图像复原与可视化模块	62
批量任务管理与历史追溯模块	63
5.4 数据库设计	64
5.4.1 用户表设计	65
5.4.2 任务批次表设计	65
5.4.3 系统日志表设计	66
5.5 本章小结	66
第六章 总结与展望	67
6.1 工作总结	67
6.2 未来展望	68
参考文献	70
致谢	79
攻读硕士学位期间科研情况	80

插图目录

图 1.1	本文组织结构图	8
图 2.1	全色锐化任务示意图	10
图 2.2	深度图超分任务示意图	11
图 2.3	磁共振图像超分任务示意图	11
图 2.4	混合专家系统 (MoE) 架构示意图[1]	16
图 2.5	CLIP 模型架构示意图[2]	18
图 2.6	提示学习 (Prompt Learning) 在图像复原中的应用示意图[3]	19
图 3.1	单任务模型与一体化模型的范式对比	20
图 3.2	使用编码器-解码器网络架构处理不同的 GISR 子任务时, 3 个特征通道的 L2 范数分布	21
图 3.3	VP-Net 网络整体架构	22
图 3.4	视觉感知路由模块 VPRM 结构示意图	25
图 3.5	三种 GISR 子任务的数据集示例。每一行展示一个任务 (从上至下依次为: 全色锐化、磁共振图像超分、深度图超分), 包括低分辨率输入、高分辨率引导图像及高分辨率真值	28
图 3.6	动态路由机制激活热力图	35
图 4.1	MAG-Net 网络整体架构示意图	38
图 4.2	多模态提示生成模块示意图	40
图 4.3	融合多模态提示的动态路由模块示意图	42
图 4.4	一体化设置下全色锐化任务的可视化对比与误差图	45
图 4.5	一体化设置下磁共振图像超分任务的可视化对比与误差图	46
图 4.6	一体化设置下深度图超分任务的可视化对比与误差图	47
图 4.7	单任务设置下全色锐化任务的可视化对比与误差图	48
图 4.8	单任务设置下磁共振图像超分任务的可视化对比与误差图	49
图 4.9	单任务设置下深度图超分任务的可视化对比与误差图	50
图 4.10	MAG-Net 在所有数据集的所有 GISR 子任务上的提示表示 t-SNE 可视化	54
图 4.11	MAG-Net 在磁共振图像超分任务中不同超分比率下的提示表示 t-SNE 可视化	55

图 5.1 一体化引导式图像超分系统总体分层架构图 61

图 5.2 系统用户登录与认证界面 62

图 5.3 交互式图像复原与可视化界面 63

图 5.4 批量图像处理界面 64

图 5.5 历史操作记录界面 64

表格目录

表 3.1 不同一体化方法在全色锐化任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	32
表 3.2 不同一体化方法在磁共振图像超分任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	32
表 3.3 不同一体化方法在深度图超分任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	32
表 3.4 VPRM 模块有效性消融实验结果分析	33
表 3.5 不同模块位置 (Encoder/Decoder) 对各任务性能的影响分析	34
表 4.1 不同一体化方法在全色锐化任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	45
表 4.2 不同一体化方法在磁共振图像超分任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	46
表 4.3 不同一体化方法在深度图超分任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	47
表 4.4 不同单任务方法在全色锐化任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	48
表 4.5 不同单任务方法在磁共振图像超分任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	49
表 4.6 不同单任务方法在深度图超分任务上的对比结果, 最优结果用 粗体表示, 次优结果用 下划线表示	50
表 4.7 不同模块 (MPGM 与 MGRM) 消融实验结果分析	51
表 4.8 不同任务组合 (Task P, M, D) 消融实验结果分析	52
表 4.9 Text 与 Image 对联合任务性能的消融实验结果分析	53
表 5.1 用户信息表 (users)	65
表 5.2 任务批次表 (task_batches)	65
表 5.3 系统日志表 (system_logs)	66

第一章 绪论

1.1 研究背景与意义

图像是现代社会感知世界与传递信息的核心载体，在遥感对地观测、临床医学诊断及自动驾驶等关键领域发挥着不可替代的作用。然而，受限于传感器物理尺寸、光学成像机理以及高昂的硬件制造成本，直接获取高分辨率图像往往面临严峻挑战，这极大限制了下游任务的精度与可靠性。针对这一瓶颈，引导式图像超分(Guided Image Super-Resolution, GISR)技术作为一种软硬件协同的创新解决方案应运而生。其核心思想在于挖掘多模态数据间的互补性，利用同场景下易于获取的另一模态高分辨率图像作为先验引导，辅助低分辨率目标图像的重建与细节恢复。这种跨模态信息融合技术有效地以软件算法弥补了硬件成像的短板，提供了一种低成本、高效能的高质量图像获取新范式。

引导式图像超分技术在多个领域具有广泛的应用场景，典型的任务包括全色锐化、深度图超分和磁共振图像超分。全色锐化(Pansharpening) [4],[5],[6]旨在将低分辨率的多光谱图像与高分辨率的全色图像融合，生成高分辨率的多光谱图像，对于提升卫星遥感观测的精度具有重要意义；深度图超分(Depth Image Super-Resolution) [7]利用高分辨率彩色图像引导低分辨率深度图的重建，在三维重建、自动驾驶及机器人导航等领域发挥关键作用；磁共振图像超分(Magnetic Resonance Image Super-Resolution) [8],[9],[10]则利用高分辨率的解剖结构图像引导低分辨率模态图像的超分，能够在缩短扫描时间的同时提供清晰的病灶细节，辅助医疗精准诊断。这些任务虽然应用场景不同，但本质上都属于跨模态的引导图像超分任务。

尽管 GISR 技术已针对上述各个任务取得了显著进展，但现有研究多局限于“单任务(One-by-One)”范式：针对不同任务需分别训练专用模型，导致在实际部署中面临存储开销大、计算资源浪费及扩展性差等问题，更重要的是，分开训练会忽略这些任务之间的共性特征。针对上述痛点，构建能够同时处理多种 GISR 任务的“一体化(All-in-One)”模型成为当前研究热点。该研究不仅有助于探索深度学习在多模态、多任务场景下的特征解耦与知识迁移机制，解决负迁移问题，挖掘任务之间的潜在关联，具有重要的理论价值；同时，设计统一轻量化的网络架

构能显著降低算法部署的边际成本，提升资源利用率，为多领域图像增强应用提供极具性价比的解决方案，具有广泛的现实意义。本文针对此问题展开研究，并提出了两个新的 GISR 一体化方法，不仅在各个 GISR 任务中性能表现优异，更打破了任务壁垒，挖掘任务之间的深度关系价值，同时还具有高效灵活的特性。

1.2 国内外研究现状

1.2.1 引导式图像超分方法

引导式图像超分作为图像复原领域的重要分支，其发展历程主要经历了传统方法与深度学习方法两个阶段。

传统方法

在传统方法时期，研究者主要依赖手工设计的特征与数学模型，通过引入先验知识来约束图像重建过程。

在全色锐化任务中，早期的研究主要基于成分替换和多分辨率分析方法。CS 方法除了主成分分析 (PCA) [11] 和强度-色调-饱和度 (IHS) [12] 变换外，Gram-Schmidt[13] 光谱锐化和 Brovey[14] 变换也是极具代表性的算法，它们通过替换空间细节提升空间分辨率，但容易产生光谱失真。MRA 方法则通过多尺度分解注入空间细节，如小波变换[15]、拉普拉斯金字塔[16] 和轮廓波变换[17]。随着优化理论的发展，基于稀疏表示[18] 和变分模型[19] 的全色锐化方法逐渐兴起，这类方法通过联合构建高、低分辨率字典[20] 或引入全变分正则化项[21]，在提升空间细节的同时有效缓解了光谱退化问题。

在深度图超分任务中，由于深度图往往具有大片平滑区域和锐利的深度边缘，传统方法致力于在放大分辨率时避免边缘模糊和伪影。除了经典的基于局部滤波的算法（如联合双边滤波[22]、引导滤波[23]）之外，基于马尔可夫随机场的概率图[24] 模型被广泛应用，它通过构建数据项和平滑项，结合高分辨率彩色图像的边缘先验来推断高分辨率深度图。此外，基于全局优化的变分方法，广义全变分正则化的算法[25]，能够更好地保护深度图的深度不连续性（跳跃边缘）并抑制阶梯效应。随后，基于字典学习[26] 和自回归模型[27] 的方法也被引入该领域，进一步提升了深度图的重建精度。

在磁共振图像超分任务中,早期的传统方法多依赖于插值算法,但这些方法往往会模糊病灶细节。为了保留医学图像中关键的解剖结构,研究者引入了基于重建的逆问题求解框架。例如,迭代反投影法[28]和凸集投影法[28]通过迭代最小化重建误差来逼近真实的高分辨率磁共振图像切片。为了进一步抑制噪声和振铃效应,基于非局部均值超分算法[29]利用了磁共振图像内部强烈的自相似性先验。此后,基于块的稀疏表示[30]成为了该任务中传统方法的集大成者,研究人员通过联合训练低分辨率和高分辨率的磁共振图像块字典,能够在不依赖外部大规模数据集的情况下,有效恢复核磁共振图像的高频解剖细节。

基于深度学习的方法

随着计算机视觉领域深度学习的兴起,卷积神经网络(CNN)[31]及Transformer[32]等先进架构逐渐主导了GISR任务的研究。相比传统方法,深度学习方法能够通过端到端的数据驱动方式,从海量数据中自动学习复杂的非线性映射关系,显著提升了图像重建的质量与效率。

在全色锐化任务中,如同传统方法致力于平衡空间细节注入与光谱失真,深度学习方法旨在通过端到端网络解决高低分辨率图像融合中的光谱退化与空间模糊问题。随着卷积神经网络的兴起,CNN被越来越多地应用于此类任务。例如,Yang等人[33]提出了PanNet架构,将上采样的LRMS图像引入输出端,并在高通滤波域中训练网络以强化高频特征学习,Wang等人[34]介绍了一种多尺度U型CNN,利用专门设计的光谱到空间卷积进行上采样。然而,这些完全数据驱动的方法通常需要大量的成对训练样本,且缺乏物理机制的约束。为了在全色锐化中实现端到端的模型驱动学习,深度展开网络得到了广泛探索。Marivani等人[35]提出了一种受卷积稀疏编码启发的多模态展开网络;Deng等人[36]提出了一种联合多模态字典学习(JMDL)方法,并随后通过ISTA算法对其进行展开;Yang等人[37]则将记忆机制与双重先验引入到条件展开框架中。此外,为应对复杂遥感场景下的跨模态对齐误差和极高分辨率图像的计算开销,最新研究进一步拓展了该领域的边界。例如,Zhao等人[38]设计了基于空间-光谱感知增强的深度展开网络,而PAN-Crafter框架[39]则通过引入跨模态对齐感知注意力机制,显著提升了网络在处理真实世界不对齐全色锐化数据时的鲁棒性与保真度。

在深度图超分任务中,核心挑战在于真实自然退化过程中往往会产生严重的结构失真和边缘噪声,导致低分辨率深度图与高分辨率 RGB 引导图之间存在严重的结构不一致性。一些方法在解决此类真实场景问题上做出了巨大贡献。例如,Yuan 等人[40]提出学习 RGB 图像和深度图之间的“跨模态结构流”,来精确引导 RGB 结构信息的传递,从而有效保护深度图的几何不连续性。随着深度学习架构的演进,近期的研究进一步深化了对复杂模态差异与高频边缘的处理。Zhang 等人[41]提出了层次化边缘细化网络(HERN),以隐式边缘特征作为先验来精细化深度细节;Wang 等人[7]则设计了结合梯度与频率感知的结构引导网络。一些最新的框架如 MOMNet[42]和基于联合深度展开的优化学习方法[43],开始致力于解决双模态输入在空间上的轻微错位问题,使得网络在未知的真实世界退化条件下,依然能够实现任意尺度的高质量深度图重建。

在磁共振图像超分任务中,目标是利用同解剖结构的高分辨率参考对比度(如 T1 加权)来引导低分辨率目标对比度(如 T2 加权)的重建。与传统医学图像处理类似,其最大的难点在于如何在提升空间分辨率的同时,严格避免病灶信息的丢失和虚假结构(伪影)的生成。基于此,引入物理退化模型和记忆机制的优化引导网络成为重要分支。Lei 等人[44]在优化引导的保真度框架下设计了 MC-CDic,大幅提升了超分与重建效果;随后,Lei 等人[45]还提出了一种用于多对比度磁共振图像超分与重建的基于分解的变分网络方法。为了进一步减少序列信息交互中的损失,Zhou 等人[46]将最大后验(MAP)估计与基于 LSTM 的持久记忆相结合,通过建模结构相似性来减少信息丢失。近年来,生成式模型和高级注意力机制的爆发为多对比度磁共振图像超分带来了新的突破。Li 等人[47]提出了一种基于矩形窗口交叉注意力的多对比度磁共振图像超分方法,实现了任意尺度的灵活上采样;随后,Li 等人[48]更是创新性地提出了一种高效扩散模型方法,极大提升了医疗图像细节的真实感。最新的一些研究如[49]则开始探索结合状态空间模型(如视觉 Mamba),旨在保证严格医疗保真度的前提下,进一步降低生成大模型的计算复杂度与长序列建模的显存消耗。

1.2.2 一体化图像恢复研究现状

在真实世界的成像过程中,图像往往受限于环境因素或设备性能而遭受多种类型的质量退化。例如,低光照环境引入的感光噪声(Denoising)、恶劣

天气带来的雨痕 (Deraining) 与雾霾 (Dehazing), 以及相机抖动产生的运动模糊 (Deblurring) 等。传统的图像复原研究通常针对每一种特定的退化类型单独设计算法模型, 然而, 这种“一任务一模型”的策略在实际部署中面临着模型数量多、存储空间大、维护成本高等问题。为了解决这些痛点, 近年来, 一体化自然图像恢复已成为一种主流趋势, 旨在利用单一通用模型同时解决多种恢复任务, 实现高效且鲁棒的图像重建。

基于提示引导的方法

在 All-in-One 图像恢复中, 提示学习的原理是引入一组可学习的任务特定参数, 作为“导航信号”来引导统一的修复网络。模型不再盲目地处理输入图像, 而是通过一个轻量级的提示生成模块实时感知图像的退化类型 (如雨、雾、噪点), 并将其编码为高维特征向量注入主网络中, 从而动态调节网络内部的特征激活, 使同一个模型能够针对不同的退化需求切换到最适合的修复状态, 有效解决了多任务并存时的参数冲突问题。

PromptIR[3], 通过轻量级提示块引导网络动态识别并补偿多种退化类型, 实现了在单一模型内高效处理去噪、去雨及去雾等多种盲图像恢复任务。为提升图像恢复的交互性, InstructIR[50] 设计了一种能够解析人类自然语言指令的模型, 通过将文本语义融入视觉修复过程, 实现了根据用户意图精准滤除噪声、雨滴或雾气等退化因素。在处理多任务图像恢复时, CCDWDPN[51] 引入了一种因果去混杂与小波解耦机制, 通过在频域内分离退化特征与语义内容, 消除了不同任务间的潜在干扰, 从而实现了多种退化场景更为精准的特征捕捉与图像重建。Dong 等人[52] 提出了一种领域感知的任务提示表征学习方法, 旨在解决多领域图像恢复中的分布偏移问题, 通过捕捉特定场景的退化规律, 实现了在统一架构下对跨领域退化的高效复原与精细化特征补偿。Wei[53] 等人引入了一种频率提示的图像恢复框架, 专门针对智能交通系统中的视觉感知增强, 通过在频域内利用提示信息引导模型修复关键物体的细节, 从而显著提升了复杂交通场景下下游检测与识别任务的可靠性。Liu 等人[54] 提出了 UHD-Processor 框架, 通过引入渐进式频率学习与退化感知提示机制, 在统一的架构下实现了超高清 (UHD) 图像的盲复原, 通过高效捕捉高频细节与全局语义, 平衡了超大规模分辨率处理中的计算效率与修复质量。Wu 等人[55] 通过构建一种动态提示学习机制, 赋予了

全能图像恢复模型实时感知并响应不同退化类型的能力,利用输入自适应的提示符引导网络分配处理权重,从而在单支骨干网络中达成了对多种异质损坏的高效修复。

基于对比学习的方法

在 All-in-One 图像恢复中,对比学习的原理是通过构建“正负样本对”来学习任务敏感的退化表示:它强迫模型在特征空间中拉近具有相同退化类型的图像特征,并推开不同退化类型的特征,从而使模型能够像“分类器”一样在无须显式标签的情况下,自动解耦出图像的内容信息与退化属性,并以此引导恢复网络针对性地调用特定的参数路径来修复图像。

Wu 等人[56]通过引入对比提示学习机制,有效排除了全能图像恢复中的退化冗余信息,利用对比损失引导模型在潜在空间中精准区分不同的退化类型,从而显著提升了单模型处理多种复杂退化任务的判别力与修复保真度。Chen 等人[57]提出了一种统一的图像修复框架,通过两阶段知识学习(从特定天气过渡到多天气任务)与多对比正则化约束,实现了用单个模型高效去除雨、雾、雪等多种复杂天气噪声。AirNet[58]提出了对比基退化编码器(CBDE)。它利用对比学习来学习图像的退化表示,让模型能够自动识别当前的退化,并指导后续的修复网络。而无需预先知道天气类型。MCDRNet[59]提出了一种多粒度对比引导架构,通过在不同尺度上重构退化表示,并利用对比损失函数在粗粒度和细粒度两个维度上对修复特征进行校准,增强了模型对混合退化(如既有雨又有雾)或极端天气参数变化的感知灵敏度。针对对比学习中负样本质量参差不齐的问题,Cheng 等人[60]提出了渐进式负样本增强机制,通过在训练过程中动态挖掘和生成更难区分的负样本,不断“压迫”模型学习更精细的特征判别边界,从而突破了传统 All-in-one 模型在恢复边界纹理时的瓶颈。Wu 等人[61]提出了模型对比学习范式。与传统的“图像对比”不同,它将处于不同训练阶段的模型(历史模型)视为负样本,通过“Self-Prior guided Negative loss (SPN)”拉开当前模型与性能欠佳的历史模型之间的距离。这种方法不依赖于具体的退化类型,具有极强的通用性。Dap-led[62]利用大规模预训练模型 CLIP 的对比语言-图像空间,通过微调使其感知图像的退化状态。它证明了对比学习学习到的“强判别性特征”可以作为高质量的“退化

提示（Degradation Prompts）”，直接指导统一模型在多种未知退化之间进行精准切换。

1.3 本文主要工作

针对现有引导式图像超分技术在一体化模型构建中面临的任务干扰即负迁移和语义歧义性两大核心挑战，本文展开了深入研究。本文旨在设计一套能够自适应处理多种模态、多种倍率任务的一体化 GISR 框架，主要研究内容与贡献如下：

1. 本文率先打破了引导式图像超分领域长期存在的“一任务一模型”壁垒，提出了一种全新的一体化处理范式。该模式首次将全色锐化、磁共振图像超分及深度图超分整合至单一网络框架中，不仅大幅降低了多模型部署带来的存储与计算冗余，更通过联合学习充分挖掘了不同模态任务内在的结构先验与共性特征，验证了构建通用化底层视觉大模型的可行性。
2. 本文创新性地提出了视觉加语义双重驱动的任务解耦策略。将高层语义理解引入底层图像复原任务，提出了多模态提示生成与注入机制。利用文本语义先验来修正纯视觉感知的偏差，实现了从物理特征解耦到语义意图解耦的认知升维，提升了模型对特定领域任务的适应性。
3. 本文构建了高性能的一体化应用闭环。提出的一体化模型在多个标准数据集上均取得了超越单任务 SOTA 专用模型的性能表现，证明了一体化架构的优越性。同时，通过开发完整的 Web 演示系统，打通了从算法模型到终端应用的隔阂，验证了该技术在工程场景中的可用性与鲁棒性。

1.4 论文组织结构

本文共分为六章，如图 1.1 各章节组织结构如下：




图 1.1 本文组织结构图

第一章，绪论。阐述引导式图像超分技术的研究背景与现实意义。全面梳理和分析国内外在单任务 GISR 方法（包括传统方法与深度学习方法）以及一体化图像恢复领域的研究现状。在此基础上，总结现有技术面临的痛点，并详细列出本文旨在解决多模态任务协同的三个主要研究内容与创新点，最后给出整篇论文的章节安排。

第二章，相关理论与技术基础。系统介绍引导式图像超分的数学定义，并详细阐明全色锐化、深度图超分和磁共振图像超分三个子任务的物理含义与相应的客观评价指标。深入探讨一体化图像恢复技术的理论基础，涵盖 Transformer 与 ViT 架构、Restormer 核心组件，以及混合专家系统（MoE）的动态路由机制和多模态预训练模型与提示学习的基本原理，为后续算法设计奠定理论基石。

第三章，面向一体化任务的视觉感知与动态路由 GISR 方法。针对一体化 GISR 任务联合训练时存在的参数干扰与负迁移问题，提出一种基于视觉感知与动态路由的图像重建方法（VP-Net）。详细阐述该网络的整体架构以及视觉感知路由模块的设计细节，该模块利用引导图像的高频视觉特征动态激活特定专家网络，实现特征的物理解耦。最后，通过在三个典型任务上的丰富对比实验、消融实验及动态路由机制的可视化分析，验证该方法在缓解任务冲突方面的有效性。

第四章，融合多模态语义提示的一体化 GISR 方法。针对 VP-Net 中纯视觉感知机制存在的视觉歧义性与语义缺失局限，提出一种融合多模态语义提示的增强

型一体化重建方法（MAG-Net）。重点剖析多模态提示生成模块（MPGM）的运作机制，以及融合语义提示的动态路由模块（MGRM）如何实现视觉+语义的双重驱动。通过全面的对比实验、任务组合消融及提示表示的 t-SNE 可视化，论证引入高层语义先验对于实现彻底解耦和提升重建性能的必要性及优越性。

第五章，一体化引导式图像超分系统。为降低先进算法的使用门槛并服务于垂直领域专家，设计并开发基于 B/S 架构的一体化演示系统。详述系统的功能性与非功能性需求分析，展示包含展示层、服务层、算法层和数据层的四层总体架构。具体介绍用户认证、交互式图像复原与可视化、批量任务管理与历史追溯等核心功能模块的设计与实现过程，并给出支撑系统运行的 MySQL 数据库表结构设计。

第六章，总结与展望。对全文的研究工作进行总结，分析存在的不足，并对未来的研究方向进行展望。

第二章 相关理论与技术基础

2.1 引导式图像超分基础

2.1.1 问题数学定义

引导式图像超分的核心目标是利用高分辨率的引导图像 I_{guide} 作为辅助信息, 将低分辨率的目标图像 I_{LR} 重建为高分辨率图像 I_{SR} 。假设 $I_{\text{LR}} \in \mathbb{R}^{H \times W \times C_{\text{in}}}$, $I_{\text{guide}} \in \mathbb{R}^{sH \times sW \times C_{\text{guide}}}$, 其中 s 为超分倍率, C_{in} 和 C_{guide} 分别为目标图像和引导图像的通道数[63], [22]。该过程可以抽象为一个非线性映射函数 F :

$$I_{\text{SR}} = F(I_{\text{LR}}, I_{\text{guide}}; \theta) \approx I_{\text{GT}}, \quad (2.1)$$

其中, $I_{\text{SR}} \in \mathbb{R}^{sH \times sW \times C_{\text{in}}}$ 为重建结果, I_{GT} 为对应的高分辨率真实标签, θ 为模型参数。根据具体的应用场景, 输入与输出的物理含义各不相同。以下将从全色锐化、深度图超分和磁共振图像超分三个子任务分别介绍各个值对应的物理含义。

全色锐化

全色锐化任务中, I_{LR} 为低分辨率的多光谱图像 (Multi-Spectral, MS), 包含丰富的光谱信息; I_{guide} 为高分辨率的全色图像 (Panchromatic, PAN), 包含清晰的空间几何结构。目标是生成既具有高空间分辨率又保留原始光谱特性的高分辨多光谱图像。如图 2.1 所示, 全色锐化旨在将低分辨率多通道 (4 或 8 甚至更多) 的多光谱图像与高分辨率的单通道全色图像融合, 生成高分辨率的彩色图像。




图 2.1 全色锐化任务示意图

深度图超分

在深度图超分任务中, I_{LR} 为低分辨率深度图, 通常含有噪声; I_{guide} 为同场景的高分辨率 RGB 彩色图像。如图 2.2 所示, 目标是利用 RGB 图像的边缘纹理引导深度图的边缘恢复, 同时防止纹理拷贝伪影。




图 2.2 深度图超分任务示意图

磁共振图像超分

磁共振图像超分任务中, I_{LR} 为低分辨率的某一模态 MR 图像 (如 T2 加权像), 扫描速度快但细节模糊; I_{guide} 为高分辨率的另一模态 MR 图像 (如 T1 加权像)。目标是利用 T1 的解剖结构细节信息辅助 T2 图像的重建。如图 2.3 所示, 通常利用 T1 加权像作为引导图像, 增强 T2 加权像的空间分辨率。




图 2.3 磁共振图像超分任务示意图

2.1.2 引导式图像超分任务评价指标

为了量化评估重建图像 I_{SR} 与真实标签 I_{GT} 之间的差异，本文采用了多种主流的客观评价指标。

峰值信噪比（PSNR）

PSNR 是最常用的图像质量评价指标，基于均方误差（MSE）计算，单位为 dB。对于 N 位深度的图像，计算公式如下：

$$\text{MSE} = \frac{1}{sH \times sW \times C_{\text{in}}} \|I_{\text{SR}} - I_{\text{GT}}\|_2^2, \quad (2.2)$$

$$\text{PSNR} = 10 \cdot \log_{10} \left(\frac{(2^N - 1)^2}{\text{MSE}} \right), \quad (2.3)$$

其中， I_{SR} 和 I_{GT} 分别表示重建图像和真实高分辨率图像， $sH \times sW$ 为图像的空间分辨率， C_{in} 为图像通道数。 $2^N - 1$ 代表图像像素可能达到的最大数值（如 8 位图像为 255）。PSNR 值越高，表示重建图像在像素级上越接近真实值，图像失真越小。

结构相似度（SSIM）

SSIM 从亮度（Luminance）、对比度（Contrast）和结构（Structure）三个维度衡量图像的相似性，更符合人眼的视觉感知特性。其计算公式为：

$$\text{SSIM}(x, y) = \frac{(2\mu_x\mu_y + c_1)(2\sigma_{xy} + c_2)}{(\mu_x^2 + \mu_y^2 + c_1)(\sigma_x^2 + \sigma_y^2 + c_2)}, \quad (2.4)$$

其中， x 和 y 分别代表从重建图像和真实图像中提取的图像块。 μ_x, μ_y 分别为 x 和 y 的均值，反映亮度信息； σ_x^2, σ_y^2 分别为 x 和 y 的方差，反映对比度信息； σ_{xy} 为协方差，反映结构相似性。 c_1 和 c_2 为常数，用于避免分母为零的情况（通常取 $c_1 = (k_1 L)^2, c_2 = (k_2 L)^2$ ，其中 L 为像素值的动态范围， $k_1 = 0.01, k_2 = 0.03$ ）。SSIM 取值范围为 $[0, 1]$ ，值越接近 1 表示结构保留越完整。

均方根误差（RMSE）

RMSE 常用于深度图超分任务，直接反映深度值的预测偏差。其计算公式为：

$$\text{RMSE} = \sqrt{\frac{1}{s_H \times s_W} \|I_{\text{SR}} - I_{\text{GT}}\|_2^2}, \quad (2.5)$$

其中, $\|\cdot\|_2$ 表示 L2 范数。RMSE 通过计算重建图像与真实图像对应像素差值的平方和的均值再开方, 能够敏感地反映出图像中的大误差。RMSE 值越低, 表示深度恢复越准确。

光谱角映射 (SAM)

SAM 专门用于评估全色锐化任务中的光谱失真程度, 通过计算重建图像与真实图像在每个像素位置上的光谱向量之间的夹角来度量。公式如下:

$$\text{SAM}(\mathbf{v}, \hat{\mathbf{v}}) = \arccos\left(\frac{\mathbf{v} \cdot \hat{\mathbf{v}}}{\|\mathbf{v}\|_2 \cdot \|\hat{\mathbf{v}}\|_2}\right), \quad (2.6)$$

其中, $\mathbf{v}$ 和 $\hat{\mathbf{v}}$ 分别表示真实多光谱图像和重建全色锐化图像在同一像素位置的光谱向量(向量长度等于波段数)。SAM 计算的是这两个向量在光谱空间中的角度, 与光照强度无关。SAM 值通常以度或弧度为单位, 值越小, 表示重构图像的光谱特性(即波段间的相对比例关系)保持得越好。

综合相对全局误差 (ERGAS)

ERGAS 综合考虑了空间分辨率与光谱质量, 是一个全局性的误差指标, 尤其适用于评估多波段图像的融合质量。其公式为:

$$\text{ERGAS} = \frac{100}{s} \sqrt{\frac{1}{C_{\text{in}}} \sum_{i=1}^{C_{\text{in}}} \left(\frac{\text{RMSE}_i}{\mu_i}\right)^2}, \quad (2.7)$$

其中, s 为高分辨率全色图像与低分辨率多光谱图像的空间分辨率之比(即超分倍率); C_{in} 为波段总数; RMSE_i 为第 i 个波段的均方根误差; μ_i 为第 i 个波段的像素均值。ERGAS 值越低, 表示在考虑了各波段亮度水平和缩放比例后的整体融合质量越高。

2.2 一体化图像恢复相关基础

一体化图像恢复(All-in-One Image Restoration)旨在通过单一模型处理多种图像退化问题(如去噪、去雨、超分等), 这对模型的特征表达能力和任务适应性

提出了极高要求。传统的基于卷积神经网络 (CNN) 的方法虽然在单一任务上表现出色,但在处理多任务时往往受限于局部感受野,难以捕捉不同任务间的通用特征,且难以在同一参数空间内平衡不同任务的优化目标。

近年来,深度学习技术的发展,特别是 Transformer 架构的引入,为一体化图像恢复提供了新的解决思路。Transformer 凭借其强大的全局建模能力和动态自注意力机制,能够更好地建立长距离像素依赖,从而在统一框架下有效处理具有不同统计特性的退化图像。此外,为了进一步提升模型在多任务场景下的性能与效率,研究者们引入了混合专家系统 (MoE) 与提示学习 (Prompt Learning) 等机制,使得模型能够根据输入图像的特性动态调整计算路径,实现“一专多能”。本节将详细介绍支撑一体化图像恢复任务的核心技术,包括 Transformer 基础架构、Restormer 骨干网络设计以及混合专家系统等。

2.2.1 Transformer 与 ViT

近年来,Transformer 架构凭借自注意力机制在自然语言处理领域的颠覆性成功,被 Dosovitskiy 等人[64] 以 Vision Transformer (ViT) 的形式引入计算机视觉。不同于传统 CNN 依赖局部感受野的卷积操作,ViT 将图像分割为非重叠 Patch 并展平为序列,利用多头自注意力机制捕捉全局长距离依赖,这使其更适合处理高分辨率图像中的复杂纹理结构。然而,标准 ViT 的计算复杂度随图像分辨率呈二次方增长,在底层视觉任务中面临巨大的显存与计算挑战。Liu 等人[65] 提出的 Swin Transformer 通过基于移位窗口的局部注意力机制,将计算复杂度降至线性。随后,SwiIR [66] 进一步将其应用于图像复原,凭借高质量的局部-全局特征表征刷新了多项基准。

为进一步平衡计算效率与特征捕捉能力,图像复原领域的 Transformer 架构持续演进。Zamir 等人[67] 提出的 Restormer 架构通过多头门控通道注意力 (MDTA) 将计算转移至通道维度,不仅规避了高分辨率输入的显存瓶颈,还利用门控前馈网络增强了非线性表达。此后,Uformer [68] 和 HAT [69] 等工作分别通过 U 型结构和混合注意力机制,进一步提升了多尺度特征捕获与边缘保真度。

2.2.2 Restormer 及核心组件

本文提出的 VP-Net 与 MAG-Net 均采用 Restormer 作为基础骨干网络。Restormer 专为图像复原任务设计，能够在保持计算效率的同时有效提取多尺度特征，其整体采用了多尺度分层设计，核心组件包括多头转置注意力机制（MDTA）和门控前馈网络（GDFN）。

多头转置注意力机制

传统的自注意力机制（如 ViT 中使用的）计算复杂度与图像像素数量的平方成正比（ $O((HW)^2)$ ），在高分辨率图像处理中显存开销巨大。Restormer 提出的 MDTA 将注意力计算从空间维度转移到了通道维度。假设输入特征为 $X \in \mathbb{R}^{H \times W \times C}$ ，MDTA 首先生成查询（Query）、键（Key）和值（Value）投影： $Q, K, V \in \mathbb{R}^{H \times W \times C}$ 。然后将特征重塑为 $\mathbb{R}^{HW \times C}$ ，并在通道维度计算注意力图：

$$\text{Attention}(Q, K, V) = V \cdot \text{Softmax}\left(\frac{K^T Q}{\alpha}\right), \quad (2.8)$$

其中， $K^T Q$ 生成的是 $C \times C$ 的协方差矩阵，而非传统的 $HW \times HW$ 空间注意力图。这使得计算复杂度降低为 $O(HWC)$ ，与图像分辨率呈线性关系，极大提升了处理高分辨率图像的效率。此外， α 是一个可学习的缩放参数，用于调节注意力图的幅度。

门控前馈网络

标准 Transformer 中的前馈网络（FFN）通常由两个全连接层和 GELU 激活函数组成。Restormer 引入了门控前馈网络 GDFN 来增强特征变换的非线性表达能力。GDFN 包含两个并行的路径，通过 1×1 卷积扩展通道数，接着使用 3×3 深度可分离卷积（Depth-wise Convolution）来编码具备空间局部性的上下文信息。其中一条路径经过 GELU 激活后作为门控信号，与另一条路径进行逐元素相乘：

$$X_{\text{out}} = W_p^0(\text{GELU}(W_d^1(W_p^1(X))) \odot W_d^2(W_p^2(X))), \quad (2.9)$$

其中， $\odot$ 表示逐元素乘法， W_p 表示 1×1 点卷积， W_d 表示 3×3 深度卷积。这种门控机制允许网络有选择地传递信息流，从而更精细地控制特征的激活与抑制。

2.2.3 混合专家系统基本原理

混合专家系统 (Mixture-of-Experts, MoE) [1] 是一种条件计算模型, 旨在通过增加模型容量而不增加计算量来提升性能。MoE 的核心思想是将一个大的神经网络分解为多个并行的子网络, 即专家 (Experts), 并引入一个门控网络 (Gating Network) 来决定对于每一个输入样本, 应该激活哪些专家进行处理。假设有 N 个专家网络 $\{E_1, E_2, \dots, E_N\}$, 对于输入 x , MoE 的输出 y 可以表示为各专家输出的加权和:

$$y = \sum_{i=1}^N G(x)_i E_{i(x)}, \quad (2.10)$$

其中, $G(x)$ 是门控网络的输出向量, $G(x)_i$ 表示第 i 个专家的权重。在深度学习中, MoE 通常被嵌入到 Transformer 的 FFN 层或卷积层中, 使得模型能够针对不同的输入模式 (如不同的语义、纹理或模态) 学习专门的参数表示。如图 2.4 所示, 门控网络根据输入决定激活哪些专家, 并将各专家的输出进行加权聚合。




图 2.4 混合专家系统 (MoE) 架构示意图[1]

Top-K 稀疏路由

为了保证推理效率，MoE 通常采用稀疏路由策略，即对于每个输入，只激活一小部分专家。该策略通过噪声门控、Top-K 筛选与概率归一化三个环节实现高效的条件计算。

为了增加探索性并促进负载均衡，模型首先计算带有可学习噪声的门控分数：

$$H(x) = x \cdot W_g + \text{SN}() \cdot \text{Softplus}(x \cdot W_{\text{noise}}), \quad (2.11)$$

其中， x 为输入特征， W_g 为门控网络的权重矩阵， $\text{SN}()$ 表示标准正态分布采样， Softplus 为激活函数， W_{noise} 为可学习的噪声参数矩阵。

随后，为了实现计算的稀疏性，模型执行 Top-K 筛选操作，仅保留得分最高的 k 个专家，将其余专家的得分置为负无穷：

$$\text{TopK}(v, k)_i = \begin{cases} v_i & \text{if } v_i \text{ is in top } k \text{ elements} \\ -\infty & \text{otherwise} \end{cases}. \quad (2.12)$$

最后，通过 Softmax 函数将保留下来的得分转化为概率分布，作为各专家的权重：

$$G(x) = \text{Softmax}(\text{TopK}(H(x), k)). \quad (2.13)$$

这种机制使得门控网络 $G(x)$ 具有稀疏性，在拥有极大规模参数量的同时，实际计算量仅与被激活的 k 个专家相关。

在 MoE 训练过程中，常见的挑战是路由坍缩现象，即门控网络倾向于将大多数样本分配给少数几个表现较好的专家，导致这些专家过载，而其他专家处于闲置状态。这不仅浪费了模型容量，也限制了专家的专业化分工。为了解决这一问题，通常会引入负载均衡损失：

$$\mathcal{L}_{\text{balance}} = N \cdot \sum_{i=1}^N f_i \cdot P_i, \quad (2.14)$$

其中， N 是专家数量， f_i 是第 i 个专家在当前 Batch 中被选中的频率， P_i 是第 i 个专家的平均累积门控概率。最小化该损失函数将鼓励所有专家被接收相等数量的样本，且具有相近的平均重要性。

2.3 多模态预训练模型与提示学习

2.3.1 视觉-语言大模型

视觉-语言预训练模型旨在建立图像与文本之间的语义关联。OpenAI 提出的 CLIP（Contrastive Language-Image Pre-training）[2] 是其中的里程碑式工作。如图 2.5 所示，CLIP 包含一个文本编码器（Text Encoder, 通常是 Transformer）和一个图像编码器（Image Encoder, ResNet 或 ViT）。




图 2.5 CLIP 模型架构示意图[2]

CLIP 的核心创新在于通过大规模的对比学习，将图像和其对应的文本描述映射到一个共享的联合嵌入空间。在该空间中，匹配的图像-文本对（正样本）的特征向量余弦相似度被最大化，而不匹配的对（负样本）则被最小化。这使得 CLIP 具备了强大的零样本（Zero-shot）迁移能力和跨模态语义对齐能力，能够理解具有丰富语义的文本指令。

2.3.2 提示学习

提示学习（Prompt Learning）最初起源于自然语言处理领域，旨在通过设计特定的输入 Prompt 来激发预训练大语言模型处理下游任务的能力，而无需微调整个模型参数。提示可以分为两类：

1. 硬提示：由人类专家手工设计的离散文本字符，例如“把这句话翻译成中文”。
2. 软提示：由可学习的连续向量组成，通过反向传播在特定任务上进行优化。

如图 2.6 所示，在计算机视觉及多模态领域，提示学习被引入用于适应不同的视觉任务。通过将任务描述（如“去噪”、“超分”、“风格迁移”）转化为提示向量注入到模型中，可以动态调整模型的行为。




图 2.6 提示学习 (Prompt Learning)在图像复原中的应用示意图[3]

在 GISR 任务中，引入提示学习的意义在于：传统模型对全色锐化等任务差异缺乏显式的认知。通过利用 CLIP 等视觉-语言预训练模型提取任务描述的语义特征作为提示，可以赋予底层视觉模型对高层任务意图的理解能力，从而指导模型根据具体的任务需求（如保持光谱一致或恢复几何结构）进行针对性的图像重建。

2.4 本章小结

本章系统梳理了引导式图像超分及一体化模型的理论基础。首先阐述了引导式超分的数学定义，并介绍了全色锐化等三个子任务的物理含义与评价体系。然后回顾了一体化恢复技术基础，阐述了 Restormer 骨干网络、混合专家系统以及多模态提示学习原理。

第三章 面向一体化任务的视觉感知与动态路由 GISR 方法

3.1 引言

引导式图像超分在遥感观测、医学诊断及自动驾驶等领域发挥着不可替代的作用，其核心思想是利用同场景下易获取的另一模态高分辨率图像作为辅助，指导低分辨率目标图像的重建。尽管深度学习技术推动了 GISR 的显著进展，但现有研究多局限于单任务范式：针对全色锐化、深度图超分、磁共振超分等不同任务，需分别设计并训练专用模型。这种割裂的训练方式不仅导致实际部署中存储开销大、计算资源浪费及扩展性差等问题，更重要的是忽略了这些任务之间潜在的共性特征。因此，如图 3.1 (b) 所示，构建能够统一处理多种 GISR 任务的一体化模型，探索多模态场景下的特征解耦与知识迁移机制，已成为当前图像复原领域的重要研究方向。




图 3.1 单任务模型与一体化模型的范式对比

尽管一体化模型具有极高的应用价值，但其训练过程面临着严峻的挑战。与去噪、去雨等自然图像复原任务不同，GISR 涵盖了全色影像、深度图和磁共振影像等多种差异巨大的数据模态。这些模态在成像机理、频谱特性以及纹理结构上存在显著的分布差异。如果简单地将所有任务的数据混合，强制使用一个共享参数的骨干网络进行训练，不同任务的梯度更新方向往往会发生冲突，导致模型参数在优化过程中产生震荡。这种现象被称为任务干扰或负迁移，不同任务的优化

方向不同，导致一体化模型在某些子任务上的性能反而低于单独训练的专用模型。

在设计一体化网络之前，需要先深入理解不同 GISR 子任务在特征空间中的分布特性。为了探究多任务混合训练时潜在的干扰机制，对一个本章方法所使用的基础 Encoder-Decoder 网络模型 Restormer [67]，在处理不同任务时的中间特征进行了统计分析。

图 3.2 展示了不同任务在编码-解码架构中某些通道的 L_2 范数分布情况。从图中可以清晰地观察到，特征激活的高度特定于任务的变化，表明从不同 GISR 子任务中提取的特征表现出显著的独立性。这一观察结果表明，当使用统一网络处理多个 GISR 子任务时，输入模式的变化可能会导致任务之间的干扰，最终阻碍网络在所有子任务中实现最佳性能的能力。




图 3.2 使用编码器-解码器网络架构处理不同的 GISR 子任务时，3 个特征通道的 L_2 范数分布

为了解决上述任务干扰问题，打破多任务协同训练的瓶颈，并充分利用高分辨率引导图片的指导能力，本章提出了一种面向一体化任务的视觉感知与动态路由 GISR 方法 (Visual-Perception, VP-Net)。该方法摒弃了传统静态网络的参数共享机制，引入了 MoE 架构思想 [1]，旨在通过网络结构的动态化来实现特征的物理解耦。具体而言，本文设计了一个视觉感知路由模块 (Visual-Perception Routing Module, VPRM)，该模块利用输入图像自身的底层视觉特征（如纹理、边缘、灰度分布等），以及引导图片中提取的视觉特征，共同作为隐式的感知信号，为每个像素动态分配最匹配的专家网络路径。

通过这种基于视觉感知的动态路由机制，模型能够根据输入数据的模态特性，自适应地激活特定的计算分支。例如，全色锐化任务倾向于激活处理高频细节的专家，而深度图超分任务则可能更多地依赖处理平滑梯度的专家。这种机制在不显著增加计算量的前提下，有效地隔离了不同任务间的特征干扰，使得模型既能保留对共性特征的学习能力，又能兼顾不同模态的特异性需求。本章将详细阐述该方法的网络架构设计、动态路由机制的实现细节，并通过一系列实验验证其在一体化 GISR 任务中的有效性。

3.2 算法概述

本节将首先阐述模型的整体网络架构,随后详细介绍核心组件——基于视觉感知的动态路由模块的设计细节与工作机制,最后给出用于指导模型优化的损失函数定义。

3.2.1 整体网络架构




图 3.3 VP-Net 网络整体架构

如图 3.3 所示，本章提出的 VP-Net 建立在一个分层的 U 型编码器-解码器架构 Restormer 之上，旨在利用其高效的 Transformer 模块处理高分辨率特征，并通过多尺度的特征交互来捕捉图像的长距离依赖与局部细节。VP-Net 主要由三个部分组成：浅层特征提取模块、嵌入 VPRM 的编码器以及图像重建解码器。

模型的输入包含两个部分：待恢复的低分辨率目标图像 $I_{LR} \in \mathbb{R}^{H \times W \times C_{in}}$ 和高分辨率引导图像 $I_{HR} \in \mathbb{R}^{sH \times sW \times C_{guide}}$ ，其中 s 为超分倍率。

由于 I_{LR} 和 I_{HR} 来自不同的模态，且具有不同的空间分辨率，本文首先使用两个独立的 3×3 卷积层作为浅层特征提取器，分别将它们映射到统一的通道维度 C 。对于 I_{LR} ，提取得到的特征 F_0 将作为主干网络的初始输入；对于 I_{HR} ，提取得到的特征 F_{guide} 将作为视觉引导信号，被送入后续的 VPRM 中，用于指引特征的分流和 MoE 中专家的选择。

编码器旨在逐步降低特征的空间分辨率并增加通道数，以获取更大的感受野。它包含 4 个层级，每个层级由若干个 Transformer Block 堆叠而成。这些 Block 采用了 Restormer 的核心组件——多头转置注意力机制和门控前馈网络，以在特征维度上高效聚合上下文信息。与传统共享参数的 Restormer 不同，为了解决一体化训练中的任务干扰问题，在编码器的每个层级中嵌入了 VPRM。

在网络结构中，VPRM 被放置在每个层级的 Transformer Block 之后。该模块同时接收当前层级输出的主干特征 F_l^{enc} 与经过下采样的引导特征 F_{guide}^l ，其中 l 表示层级索引。 F_{guide} 中蕴含的丰富纹理、边缘和结构信息在此充当关键视觉依据，VPRM 通过融合主干特征与引导特征的统计信息，动态地计算像素级的门控权重，从而决定每个空间位置的特征应被分配至哪一组专家网络进行处理。通过这种视觉感知驱动的动态路由，网络能够依据输入图像的底层视觉特性，将特征动态分流至最适合当前纹理分布的专家网络中。这种机制在编码阶段实现了物理路径的解耦，使得不同任务能够激活不同的参数子集。例如，全色锐化任务所涉及的高频空间细节特征会被路由至擅长处理精细纹理的专家分支，而深度图超分任务中的平滑梯度特征则会被导向另一组专家。由此，不同任务的梯度更新在参数空间中被有效隔离，从根本上缓解了梯度冲突与负迁移问题。在编码器的各层级之间，空间下采样操作通过 Pixel-Unshuffle 实现。该操作将空间维度为 $H \times W$ 的特征图重组为 $\frac{H}{2} \times \frac{W}{2}$ 的特征图，同时通道数增加为原来的 4 倍，随后通过一个 1×1 卷积层将通道数调整至目标维度。相较于传统的步幅卷积（Strided Convolution）或池化（Pooling）操作，Pixel-Unshuffle 在减少空间维度的同时能够完整保留通道信息，有效避免了下采样过程中的信息丢失。

解码器由 4 个与编码器对称的层级组成，负责逐步恢复图像的空间分辨率。每个解码器层级包含对应数量的 Transformer Block，用于从深层编码特征中重建

高频细节与精细纹理。为了弥补逐层下采样过程中不可避免的空间信息损失，网络引入了跳跃连接（Skip Connections），将编码器各层级的输出特征与解码器对应层级的输入特征在通道维度上进行拼接（Concatenation），并通过一个 1×1 卷积层将拼接后的通道数压缩回当前层级的标准维度。跳跃连接使得解码器在重建过程中能够直接访问编码器提取的多尺度浅层特征，从而保留更丰富的空间结构信息，提升重建图像的质量。需要说明的是，基于前期的实验观察（详见本章消融实验部分），不同任务间的特征差异主要体现在特征提取与理解阶段，即编码器部分。在解码器阶段，来自不同任务的特征经过编码器的动态路由已经被充分解耦和提纯，此时对它们进行共享参数的重建处理并不会引发显著的干扰。因此，为了保持模型的计算效率，本文在解码器阶段并未引入路由模块，而是沿用了标准的静态 Transformer Block 结构。解码器各层级之间的特征上采样通过 Pixel-Shuffle 操作实现，该操作将通道维度上的冗余信息重组到空间维度，逐步将特征图放大至目标分辨率。

经过解码器处理后，网络得到与输入 I_{LR} 具有相同空间分辨率（即 $sH \times sW$ ）的深层特征表示。该特征通过一个 3×3 卷积层映射回原始图像的通道空间，得到残差图像 $I_{res} \in \mathbb{R}^{sH \times sW \times C_{in}}$ 。最终的超分重建结果 I_{SR} 通过残差学习策略获得，即将残差图像与经双线性插值上采样至目标分辨率的输入图像相加：

$$I_{SR} = I_{res} + \text{Upsample}(I_{LR}), \quad (3.1)$$

其中， $\text{Upsample}(\cdot)$ 表示双线性插值上采样操作。这种残差学习范式使得网络只需学习低分辨率输入与高分辨率目标之间的高频差异部分，而非从零开始重建完整图像，显著降低了学习难度并加速了模型的收敛过程。

3.2.2 基于视觉感知的动态路由模块

VPRM 是 VP-Net 实现一体化多任务处理的核心组件。该模块的设计目标是利用高分辨率引导图像中蕴含的纹理、边缘与结构信息作为关键视觉依据，为主干特征中的每个空间位置动态选择最合适的专家网络进行处理，从而在参数空间中实现不同任务特征的物理隔离。VPRM 的结构如图 3.4 所示。




图 3.4 视觉感知路由模块 VPRM 结构示意图

VPRM 采用稀疏门控 MoE 架构，其内部包含三个关键组成部分：视觉感知门控网络（Visual-Perception Gating Network）、专家网络组（Expert Networks）以及稀疏分发与加权聚合机制（Sparse Dispatch & Weighted Aggregation）。

对于编码器第 l 层级，VPRM 接收两个输入：当前层级的主干特征 $F_L \in \mathbb{R}^{B \times C_l \times H_l \times W_l}$ 以及经过同步下采样的引导特征 $F_G \in \mathbb{R}^{B \times C_l \times H_l \times W_l}$ 。视觉感知门控网络首先将两者在通道维度上进行拼接，得到融合特征：

$$F_{\text{fuse}} = \text{Conv}_{1 \times 1}([\text{Concat}(F_G, F_L)]) \in \mathbb{R}^{B \times 2C_l \times H_l \times W_l}, \quad (3.2)$$

其中， $\text{Conv}_{1 \times 1}(\cdot)$ 表示 1×1 逐点卷积操作。该卷积层的作用在于对拼接后的引导特征与主干特征进行跨模态信息融合，使门控网络能够同时感知引导图像的高频结构信息与目标图像的当前特征状态。随后，融合特征 F_{fuse} 被重塑为像素级的特征向量序列 $\mathbf{f}_{\text{fuse}} \in \mathbb{R}^{N \times 2C_l}$ ，其中 $N = B \times H_l \times W_l$ 为总的空间像素数量，并通过一个可学习的线性投影层 $\mathbf{W}_g \in \mathbb{R}^{2C_l \times M}$ （ M 为专家总数）计算每个像素位置对各专家的路由分数：

$$\mathbf{s} = \mathbf{f}_{\text{fuse}} \mathbf{W}_g \in \mathbb{R}^{N \times M}. \quad (3.3)$$

在训练阶段，为了增强路由决策的探索性并防止门控网络过早坍缩至固定的专家分配模式，VPRM 引入了带噪声的 Top-K 门控机制。具体而言，通过另一组可学习参数 $\mathbf{W}_{\text{noise}} \in \mathbb{R}^{2C_l \times M}$ 生成依赖于输入的噪声标准差，并向路由分数中注入可控的高斯噪声：

$$\boldsymbol{\sigma} = \text{Softplus}(\mathbf{f}_{\text{fuse}} \mathbf{W}_{\text{noise}}) + \varepsilon, \quad (3.4)$$

$$\tilde{\mathbf{s}} = \mathbf{s} + \boldsymbol{\xi} \odot \boldsymbol{\sigma}, \quad \boldsymbol{\xi} \sim \mathcal{N}(0, \mathbf{I}), \quad (3.5)$$

其中, ε 为一个极小的正常数以保证数值稳定性, $\odot$ 表示逐元素乘法。基于带噪声的路由分数 $\tilde{\mathbf{s}}$, 门控网络为每个像素选取得分最高的 k 个专家 (在本章实现中 $k = 2$), 并对这 k 个专家的分进行 Softmax 归一化以获得最终的门控权重:

$$G(\mathbf{f}_{\text{fuse}})_i = \begin{cases} \text{Softmax}(\tilde{\mathbf{s}}_i) & \text{if } i \in \text{Top-K}(\tilde{\mathbf{s}}) \\ 0 & \text{otherwise} \end{cases}, \quad (3.6)$$

其中, $\text{Top-K}(\cdot)$ 返回分数最高的 k 个专家的索引集合。未被选中的专家对应的门控权重为零, 由此实现了稀疏激活——每个像素仅被路由至 k 个专家, 而非全部 M 个专家, 从而在引入多专家多样性的同时有效控制了计算开销。本文通过实验验证了 $k = 2, M = 4$ 的设置在性能与效率之间达到了较好的平衡, 既能充分利用多专家的优势, 又不会引入过多的计算负担。

专家网络组由 M 个结构相同但参数独立的多层感知机 (MLP) 组成。每个专家 E_i ($i = 1, 2, \dots, M$) 包含两层全连接层, 中间以 GELU 激活函数连接:

$$E_i(\mathbf{x}) = \mathbf{W}_i^2 \cdot \text{GELU}(\mathbf{W}_i^1 \mathbf{x} + \mathbf{b}_i^1) + \mathbf{b}_i^2, \quad (3.7)$$

其中 $\mathbf{W}_i^1 \in \mathbb{R}^{C_l \times d_h}$, $\mathbf{W}_i^2 \in \mathbb{R}^{d_h \times C_l}$ 分别为第 i 个专家的两个权重矩阵, d_h 为隐藏层维度 (通过膨胀因子 r 控制, 即 $d_h = r \cdot C_l$)。每个专家拥有独立的参数空间, 能够学习特定的特征变换模式, 例如某些专家专注于高频纹理的增强, 而另一些专家则擅长处理低频平滑区域。

在稀疏分发阶段, VPRM 根据门控权重将主干特征 F_L 中的像素级特征向量分发至对应的专家网络。仅门控权重非零的像素-专家对会产生实际的计算, 未被选中的专家不参与当前像素的处理。各专家独立地对分配给自身的特征子集进行变换后, 其输出通过门控权重进行加权求和, 得到最终的路由输出:

$$\hat{F}_L = \sum_{i=1}^M G(\mathbf{f}_{\text{fuse}})_i \cdot E_i(F_L). \quad (3.8)$$

最终, VPRM 的输出通过残差连接与原始主干特征相加, 确保信息流动的畅通性并降低训练难度:

$$F_L^{\text{out}} = \hat{F}_L + F_L. \quad (3.9)$$

通过上述视觉感知驱动的动态路由机制, VPRM 能够根据引导图像所提供的视觉先验信息, 在像素级别对特征进行自适应的专家分配。不同模态、不同纹理

特性的输入数据将被自动路由至不同的专家子集, 实现了特征提取路径的物理解耦, 从根本上缓解了一体化训练中的任务干扰与梯度冲突问题。

3.2.3 损失函数

VP-Net 的总体训练损失由两部分组成: 重建损失 $\mathcal{L}_1$ 和负载均衡正则化损失 $\mathcal{L}_{\text{Balance}}$, 其表达式为:

$$\mathcal{L} = \mathcal{L}_1 + \gamma \mathcal{L}_{\text{Balance}}, \quad (3.10)$$

其中, $\mathcal{L}_1$ 为像素级的 L_1 重建损失, 用于度量网络输出的超分重建图像 I_{SR} 与对应的高分辨率真实标签 I_{GT} 之间的差异:

$$\mathcal{L}_1 = \| I_{\text{SR}} - I_{\text{GT}} \|_1, \quad (3.11)$$

$\mathcal{L}_1$ 损失相较于 $\mathcal{L}_2$ 损失对异常值更为鲁棒, 能够在保持整体重建精度的同时更好地恢复图像的高频纹理细节, 已被广泛应用于图像超分任务中。

$\mathcal{L}_{\text{Balance}}$ 是专门为 MoE 架构设计的负载均衡正则化项, 其目的在于防止门控网络在训练过程中出现专家坍塌现象——即大量像素被持续分配至少数几个专家, 而其余专家长期处于闲置状态, 导致模型的参数容量未能被充分利用。该损失由重要性损失和负载损失两部分组成, 分别从权重分配和选择频率两个角度约束各专家的使用趋于均匀:

$$\mathcal{L}_{\text{Balance}} = \text{CV}^2 \left(\sum_{n=1}^N G(\mathbf{f}_{\text{fuse}}^n) \right) + \text{CV}^2(\text{Load}(\mathbf{G})), \quad (3.12)$$

其中, $\text{CV}^2(\cdot)$ 表示变异系数的平方, 定义为样本方差除以样本均值的平方, $\sum_{n=1}^N G(\mathbf{f}_{\text{fuse}}^n)$ 统计每个专家在当前批次中所获得的门控权重之和即重要性, $\text{Load}(\mathbf{G})$ 统计每个专家在当前批次中被选中的次数。当所有专家被等概率地选择且获得相同的累积权重时, 两项变异系数均趋近于零, 损失达到最小值。在实际实现中, 编码器各层级 (前三个层级) 的 VPRM 模块各自计算负载均衡损失, 并将其累加作为总的 $\mathcal{L}_{\text{Balance}}$ 。超参数 γ 作为平衡权重, 控制负载均衡正则化的强度, 在本章实验中设定为 $\gamma = 0.01$, 以确保负载均衡约束不会过度干扰主重建任务的优化方向。

3.3 实验设置

为验证本章所提出的 VP-Net 在一体化 GISR 任务中的有效性,在三个具有代表性的 GISR 子任务上进行了全面的实验评估,分别为全色锐化(Pansharpening)、深度图超分(Depth Image SR)以及磁共振图像超分(MR Image SR)。本节将依次介绍实验所用的数据集、评测指标以及训练实现细节。

3.3.1 数据集

本章实验涵盖了三类不同模态的 GISR 子任务,每类任务均选取了领域内广泛使用的公开基准数据集。图 3.5 展示了三种任务的输入与输出示例,包括低分辨率输入、高分辨率引导图像及高分辨率真值。




图 3.5 三种 GISR 子任务的数据集示例。每一行展示一个任务(从上至下依次为:全色锐化、磁共振图像超分、深度图超分),包括低分辨率输入、高分辨率引导图像及高分辨率真值

对于全色锐化任务,本文在三个不同卫星传感器的数据集上进行实验,分别为 QuickBird (QB)、WorldView-4 (WV4) 和 GaoFen-1 (GF1) [70]。这三个数据集在光谱响应特性、空间分辨率以及成像条件上各具特点,能够全面评估方法

在不同遥感场景下的泛化能力。在数据预处理阶段, 本文将原始图像对裁剪为小尺寸的训练样本, 每组训练样本包含一幅 $128 \times 128 \times 1$ 的高分辨率全色 (PAN) 图像作为引导图像、一幅 $32 \times 32 \times 4$ 的低分辨率多光谱 (LRMS) 图像作为待超分的目标图像, 以及一幅 $128 \times 128 \times 4$ 的高分辨率多光谱 (HRMS) 图像作为训练的真实标签 (Ground Truth)。超分倍率为 $4 \times$ 。

对于深度图超分任务, 本文选取了广泛认可的 NYU v2 基准数据集 [71]。该数据集包含 1449 对 RGB-D 图像, 其中 RGB 图像作为高分辨率引导图像, 深度图作为待超分的低分辨率目标图像。按照领域内通用的实验设置, 本文使用其中 1000 对图像用于训练, 剩余 449 对图像用于测试。为了全面评估方法在不同降质程度下的重建能力, 本文分别设置了 $4 \times$ 、 $8 \times$ 和 $16 \times$ 三种超分倍率。低分辨率深度图通过对原始深度图进行双三次下采样获得。

对于磁共振图像超分任务, 本文在 BrainTS 数据集上进行评估。该数据集包含 285 个多对比度磁共振体数据 (Multi-contrast MR Volumes), 涵盖了 T1、T1ce、T2 和 FLAIR 四种对比度模态。在数据准备过程中, 本文从每个体数据中选取中间 100 个切片, 并剔除内容信息不足的切片, 最终获得 20480 个切片用于训练, 2320 个切片用于测试。引导图像为同一受试者的另一对比度磁共振切片, 超分倍率分别设置为 $2 \times$ 、 $4 \times$ 和 $8 \times$ 。

3.3.2 评测指标

针对不同任务的特点, 本文采用了与之相适配的图像质量评价指标。

在全色锐化任务中, 本文采用三种互补的评价指标: 峰值信噪比 (PSNR) 用于衡量重建图像与真实标签之间的整体像素级保真度, 其值越高表示重建质量越好; 光谱角度映射 (SAM) 从光谱一致性的角度评估重建图像是否保持了原始多光谱图像的光谱特征, 其值越低表示光谱失真越小; 综合无量纲全局误差 (ERGAS) 则从全局角度综合评价空间与光谱质量, 其值越低表示整体重建质量越高。

在深度图超分任务中, 本文采用均方根误差 (RMSE) 作为主要评价指标。RMSE 直接度量重建深度图与真实深度图之间的像素级偏差, 能够反映深度值估计的精确程度, 其值越低表示重建精度越高。

在磁共振图像超分任务中, 本文采用 PSNR 和结构相似性指数 (SSIM) 两种指标对重建质量进行评估。PSNR 衡量像素级的重建精度, SSIM 则从亮度、对比度和结构三个维度综合评价重建图像与真实标签之间的感知相似性。两项指标的值越高, 均表示重建质量越好。

3.3.3 实验细节

所有实验均基于 PyTorch 深度学习框架实现, 在单块 NVIDIA RTX 3090 GPU 上进行训练和测试。模型训练采用 Adam 优化器, 批次大小设置为 4, 初始学习率设定为 4×10^{-4} , 并采用余弦退火学习率调度策略在训练过程中逐步衰减学习率。

在骨干网络的架构配置方面, 编码器-解码器的四个层级分别包含 $L_1 = 3$ 、 $L_2 = 4$ 、 $L_3 = 4$ 、 $L_4 = 5$ 个 Transformer Block, 体现了由浅到深逐步增加模型容量的设计理念。特征通道维度 C 设定为 42, 各层级的注意力头数分别为 1、2、4、8, 门控前馈网络的通道膨胀因子设为 2.66。在 VPRM 模块中, 专家总数 $M = 4$, 每个像素激活的专家数 $k = 2$ 。负载均衡损失的权重系数 $\gamma = 0.01$ 。

在一体化训练设置中, 模型在三个任务的所有数据集上进行联合训练。由于不同任务的数据集规模存在差异, 本文将每个训练轮次的长度对齐至最小数据集 (深度图超分任务的 1000 对训练样本)。在每个轮次结束后, 所有数据集均进行重新随机打乱, 以确保训练过程中的样本多样性。模型总共训练 500 个轮次。在单任务训练设置中, 模型分别在各任务的数据集上独立训练, 每个任务同样训练 500 个轮次, 以便与一体化设置进行公平对比。

3.4 实验结果

实验主要包含两个部分: 首先通过对比实验, 验证 VP-Net 在多任务混合训练设置下相较于基准模型及通用模型的性能优势; 其次通过消融实验, 深入探究 VPRM 的核心贡献及架构设计选择; 最后通过可视化分析, 直观展示动态路由机制在特征空间中的工作机理。

3.4.1 对比实验

为了验证本章方法在多任务联合训练模式下的有效性，本文将 VP-Net 与近年来提出的主流一体化图像复原网络进行了全面对比，对比方法包括 Gridformer [72]、Transweather [73]、CAPTNet [74]、AdaIR [75] 以及 PromptIR [3]。

在进行对比实验时，本文需要克服一个技术障碍：现有的通用一体化图像复原方法（如 Transweather、PromptIR）通常仅针对 RGB 图像设计，默认输入通道为 3。然而，GISR 任务涉及多模态数据，且通道数各异。全色锐化：4 通道的 LRMS 图像和 1 通道的 PAN 图像；深度图超分：3 通道的 RGB 图像和 1 通道的 Depth 图像；磁共振图像超分：1 通道的 T1 图像和 1 通道的 T2 图像。为了公平地将这些基准方法应用于 GISR 任务，本文参考了 VP-Net 的输入处理方式，对基准模型的输入层进行了轻量级适配：针对每个特定的输入通道配置，本文分别初始化了独立的浅层特征映射层，将不同维度的原始输入映射到统一的特征维度 C 。这种处理方式在不改变基准模型核心架构与参数量级的前提下，使其能够兼容多模态、多维度的 GISR 数据输入。

表 3.1 展示了全色锐化任务在 WV4、QB 和 GF1 三个卫星数据集上的定量评估结果。可以看出，VP-Net 在绝大多数指标上均取得了最优（Bold）的成绩。特别是与同样基于 Transformer 架构的 PromptIR 相比，VP-Net 在保持参数量相当的情况下，PSNR 指标得到进一步提升，这得益于 VPRM 对不同光谱特征的精细化处理。

表 3.2 和表 3.3 分别列出了磁共振图像超分和深度图超分任务的对比数据。在 MR 图像超分中，VP-Net 在 $2\times$ 、 $4\times$ 和 $8\times$ 三个尺度上均表现出一致的性能优势。在深度图超分任务中，VP-Net 的 RMSE 误差始终低于或持平于最强基准 PromptIR，尤其是在高倍率（ $16\times$ ）重建中，能够更好地重构深度结构。实验结果表明，通过动态路由实现特征的物理解耦，能够有效避免不同模态任务之间的负迁移现象，从而打破整体系统的性能瓶颈。

表 3.1 不同一体化方法在全色锐化任务上的对比结果，最优结果用粗体表示，次优结果用下划线表示

Method	Parameters	WV4			QB			GF1		
		PSNR↑	SAM↓	ERGAS↓	PSNR↑	SAM↓	ERGAS↓	PSNR↑	SAM↓	ERGAS↓
Gridformer	6.8M	40.49	1.42	1.19	47.72	0.96	0.70	45.59	0.98	0.97
Transweather	38.0M	39.54	1.67	1.39	46.26	1.14	0.80	43.99	1.22	1.18
CAPTNet	8.0M	41.10	1.38	1.15	47.92	0.94	0.68	48.94	0.70	0.77
AdaIR	10.2M	<u>43.46</u>	<u>1.06</u>	<u>0.85</u>	<u>49.90</u>	0.75	0.54	51.80	<u>0.47</u>	<u>0.54</u>
PromptIR	28.5M	43.34	1.08	0.88	49.76	<u>0.76</u>	<u>0.55</u>	<u>52.20</u>	0.46	0.53
VPNet	4.7M	43.71	1.03	0.83	50.00	0.75	0.54	52.24	0.46	<u>0.54</u>

表 3.2 不同一体化方法在磁共振图像超分任务上的对比结果，最优结果用粗体表示，次优结果用下划线表示

Method	Parameters	2x		4x		8x	
		PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑
Gridformer	6.8M	42.15	0.9890	36.70	0.9662	33.64	0.9430
Transweather	38.0M	39.91	0.9821	36.25	0.9594	33.73	0.9332
CAPTNet	8.0M	40.43	0.9872	35.05	0.9573	32.09	0.9249
AdaIR	10.2M	<u>44.27</u>	0.9928	38.92	0.9780	35.56	<u>0.9585</u>
PromptIR	28.5M	44.16	<u>0.9926</u>	<u>38.97</u>	<u>0.9781</u>	<u>35.58</u>	0.9582
VPNet	4.7M	44.34	0.9928	39.02	0.9783	35.59	0.9589

表 3.3 不同一体化方法在深度图超分任务上的对比结果，最优结果用粗体表示，次优结果用下划线表示

Method	Parameters	X4	X8	X16
		RMSE↓	RMSE↓	RMSE↓
Gridformer	6.8M	1.67	3.04	5.72
Transweather	38.0M	2.97	4.14	6.20
CAPTNet	8.0M	1.64	2.88	5.13
AdaIR	10.2M	1.53	<u>2.79</u>	5.09
PromptIR	28.5M	<u>1.48</u>	2.69	<u>4.89</u>
VPNet	4.7M	1.47	2.69	4.88

3.4.2 消融实验

为了验证 VP-Net 中核心设计选择的合理性, 本文进行了一系列消融实验。实验主要关注两个方面: 一是 VPRM 本身的有效性, 二是 VPRM 在网络架构中的最佳部署位置。

VPRM 有效性消融分析

为了验证 VPRM 在缓解多任务干扰方面的贡献, 本文构建了一个基准模型 (w/o VPRM), 即移除 VP-Net 中所有的 VPRM 模块, 退化为标准的共享参数 Restormer 架构, 并在相同的数据设置下进行多任务联合训练。表 3.4 展示了基准模型与完整 VP-Net 的性能对比。

由表可知, 相较于基准模型, 引入 VPRM 后的 VP-Net 在所有任务的各项指标上均取得了显著提升。例如, 在全色锐化任务的 GF1 数据集上, PSNR 提升了近 1 dB; 在深度图超分任务中, RMSE 误差也得到明显降低。这一结果充分表明, 简单的参数共享策略在处理差异巨大的异构模态时存在局限性, 而 VPRM 通过基于视觉特征的动态路由机制, 成功实现了任务特征的物理解耦, 有效缓解了负迁移现象, 从而大幅提升了一体化模型的重建质量。

表 3.4 VPRM 模块有效性消融实验结果分析

Method	Pansharpening			MR Image SR			Depth Image SR		
	WV4	QB	GF1	2×	4×	8×	4×	8×	16×
w/o VPRM	43.23	49.55	51.29	43.77	38.03	34.87	1.58	2.85	4.97
VPNet	43.71	50.00	52.24	44.34	39.02	35.59	1.47	2.69	4.88

VPRM 位置消融分析

VPRM 应当部署在网络的什么位置才能最大化其效能? 为了回答这个问题, 本文对比了三种不同的部署策略: 仅在编码器中部署 (即 VP-Net), 仅在解码器中部署; 同时在编码器和解码器中部署。实验结果如表 3.5 所示。

首先, 对比 Encoder 和 Decoder 的结果可以发现, 将路由模块置于编码阶段的性能明显优于解码阶段。这印证了本文的假设: 不同任务间的模态差异主要存在于特征提取与理解阶段。在编码器中尽早进行特征分流与解耦, 能够有效避免特征在深层发生混淆, 为后续重建打下良好基础。

其次，对比 Encoder 与 Both 方案，可以观察到 Both 设置虽然在全色锐化和磁共振超分任务上取得了极其微弱的性能优势，例如 Pan WV4 上 PSNR 仅高出 0.02 dB，但在深度图超分任务上，其性能甚至略逊于仅编码器设置。更关键的是，双端部署带来了巨大的计算代价。引入更多的专家网络不仅显著增加了模型的参数量，还大幅提高了推理延迟。此外，过多的动态路由决策节点显著增加了训练的复杂性，导致模型优化难度增大，极难收敛。综合考虑性能、效率与训练稳定性，本文认为仅在编码器中部署 VPRM 是最优的选择，它在保持高效推理的同时，实现了与更复杂模型相当的性能表现。

表 3.5 不同模块位置（Encoder/Decoder）对各任务性能的影响分析

Position	Pansharpening			MR Image SR			Depth Image SR		
	WV4	QB	GF1	2×	4×	8×	4×	8×	16×
Decoder	43.53	49.97	51.93	44.20	39.01	35.59	1.50	2.74	4.94
Encoder(VPNet)	<u>44.01</u>	<u>50.15</u>	<u>52.52</u>	<u>44.64</u>	<u>39.21</u>	<u>35.60</u>	1.29	2.47	4.45
Both	44.03	50.16	52.57	44.65	39.23	35.63	1.29	<u>2.48</u>	<u>4.47</u>

3.4.3 动态路由机制的可视化分析

为了直观地揭示 VP-Net 如何缓解多任务干扰，本文可视化了不同任务在编码器各层级（L1-L4）对各个专家（E0-E3）的平均激活率。激活热力图如图 3.6 所示，其中颜色的深浅代表每个专家被激活的频率。

从图中可以观察到明显的专家选择偏好差异，这证实了 VP-Net 成功实现了基于任务特性的特征解耦：

浅层（L1）的显著分化

在网络的浅层，专家选择的差异最为剧烈。例如，MRI 任务极度依赖专家 E1（深蓝色高亮），而对其他专家（特别是 E2 和 E3）的激活率极低。相反，Pan 任务则表现出对专家 E2 和 E3 的偏好，对 E0 和 E1 的依赖相对较少。这表明网络在特征提取的早期阶段就已经开始区分不同模态的视觉特征，将光谱信息丰富的全色影像与解剖结构复杂的磁共振影像路由至完全不同的处理路径，从而从源头上避免了特征混淆。

深层（L4）的趋同性

随着网络层级的加深，不同任务的专家激活分布逐渐趋于均匀（颜色差异变浅）。这说明在深层语义空间中，尽管输入模态不同，网络提取的高层抽象特征开始表现出一定的共性（如对物体轮廓或纹理复原的通用需求）。此时，各任务开始共享更多的专家参数，实现了知识的迁移与互补。

任务间的独特性与重叠

深度图超分任务与全色锐化任务在某些专家（如 L1_E1）上的激活模式存在重叠，但也保留了自身的独特性。这种部分共享、部分独立的路由机制正是 MoE 架构的优势所在——它既不像硬性参数隔离那样完全阻断任务间的联系，也不像全参数共享那样导致剧烈的干扰，而是通过动态门控实现了一种软性的平衡，确保每个任务都能找到最优的参数组合。

综上所述，可视化分析证实了 VPRM 能够根据输入模态的底层视觉特征，自动学习并规划出差异化的特征处理路径。这种动态分流策略不仅在理论上解释了 VP-Net 性能提升的原因，也在实践中展示了其处理多模态冲突的强大能力。




图 3.6 动态路由机制激活热力图

3.5 本章小结

本章针对多模态引导式图像超分任务中存在的负迁移与参数干扰问题，提出了一种基于视觉感知与动态路由的一体化网络模型 VP-Net。该方法通过引入 VPRM，利用引导图像的纹理与结构信息作为关键视觉依据，实现了特征处理路径的动态规划与物理隔离。

首先,本章详细阐述了 VP-Net 的整体架构设计,重点介绍了 VPRM 模块如何通过稀疏门控机制在像素级别分配专家网络,从而解决不同模态数据在特征空间中的分布冲突。其次,通过在全色锐化、磁共振图像超分和深度图超分三个典型任务上的广泛实验,验证了 VP-Net 在一体化训练设置下相较于现有 SOTA 方法的性能优势。特别是在处理异构模态数据时,VP-Net 展现出了优异的鲁棒性与泛化能力。最后,通过消融实验与可视化分析,深入揭示了动态路由机制在特征解耦与知识共享中的工作机理,证明了仅编码器部署策略在性能与效率之间的最佳平衡。本章的研究为构建通用、高效的多模态图像复原系统提供了新的视角与解决方案。

第四章 融合多模态语义提示的一体化 GISR 方法

4.1 引言

在前一章中,为了解决一体化 GISR 任务中存在的负迁移问题,本文尝试了一种基于纯视觉感知的解决方案——VP-Net。该方法创新性地引入了动态路由机制,利用引导图像的纹理、边缘等底层视觉特征作为隐式信号,将不同模态的数据分流至不同的专家网络进行处理。实验结果证实,这种基于视觉特征的物理隔离策略在一定程度上缓解了多任务间的优化冲突,优于传统的静态参数共享模型。

然而,VP-Net 本质上是一个仅依赖数据驱动的视觉主导版本,可视作本章所提完整方法的一个退化特例。它虽然能够“看见”图像纹理的差异,却无法真正理解任务的语义本质。在处理复杂多变的 GISR 任务时,这种仅依赖底层视觉特征的路由机制暴露出了两个关键局限:

首先是视觉歧义性。不同任务的图像在局部可能表现出极为相似的纹理统计特性。例如,平滑的深度图区域与磁共振影像的背景区域在梯度分布上可能难以区分,单纯依靠视觉感知的路由模块极易产生混淆,导致无法精确激活最优的专家组合。

其次是语义缺失。GISR 任务通常包含明确的先验定义,如数据源的传感器类型、具体的任务目标以及缩放倍率($4\times$ vs $8\times$)。这些高层语义信息对于指导模型进行针对性的重建至关重要,但在 VP-Net 中,这些关键的上下文信息被隐式包含或者完全忽略了。

为了显式地充分利用这些高层语义信息,本章在 VP-Net 的架构基础上,提出了一种融合多模态语义提示的一体化 GISR 方法 (Multi-modal All-in-one Guided Network, MAG-Net)。

MAG-Net 的核心思想在于引入文本语义先验来修正并增强动态路由的决策过程。为此,本文设计了一个多模态提示生成模块 (Multi-modal Prompt Generation Module, MPGM)。该模块利用预训练的大规模视觉-语言模型: CLIP [2] 作为文本编码器,将任务的具体描述(如“Image pair for $4\times$ depth image super-resolution task”)转化为富含语义的高维特征向量注入到动态路由网络中。

通过这种视觉感知 + 语义引导的双重驱动机制, MAG-Net 能够在像素级和任务级同时对特征进行精细化调控。高层语义提示为路由模块提供了全局的任务

上下文，消除了视觉特征的歧义性，确保任务被正确分类；而底层视觉感知则保留了对局部空间纹理的自适应能力。两者相辅相成，使得模型不仅实现了任务间的彻底解耦，更能够利用不同任务间的语义关联促进知识的正向迁移。本章将详细阐述 MAG-Net 的网络架构与提示学习机制，并通过对比实验证明，在引入语义交互后，模型在全色锐化、深度图超分及磁共振超分三个子任务上均取得了显著优于 VP-Net 及现有专用模型的性能表现。

4.2 算法概述

本章这一部分将详细阐述 MAG-Net 的实施细节。针对多模态一体化任务中纯视觉感知存在的“歧义性”与“语义缺失”问题，MAG-Net 在 VP-Net 的架构基础上进行了语义增强。其核心在于引入了任务描述文本作为显式的先验信息，并通过设计专门的模块将语义特征注入到动态路由的决策过程中，从而实现视觉+语义双重驱动的任务解耦。

4.2.1 整体网络架构




图 4.1 MAG-Net 网络整体架构示意图

如图 4.1 所示，MAG-Net 建立在一个分层的 U 型编码器-解码器骨干网络之上，整体流程包含三个关键阶段：多模态输入编码、基于语义增强的动态特征映射、以及高分辨率图像重建。

模型的输入由三部分组成：待恢复的低分辨率目标图像 $I_{LR} \in \mathbb{R}^{H \times W \times C_{in}}$ 、同场景的高分辨率引导图像 $I_{HR} \in \mathbb{R}^{sH \times sW \times C_{guide}}$ (s 为超分倍率)，以及描述当前任

务属性的自然语言文本 T 。针对图像数据,本文利用两个独立的 3×3 卷积层分别将 I_{LR} 和 I_{HR} 映射到统一的特征通道维度 C , 得到浅层特征 F_{LR}^0 和 F_{HR}^0 。其中 F_{LR}^0 作为主干网络的输入流, F_{HR}^0 则作为视觉引导信号被送入后续的路由模块。针对文本数据 T , 本文设计了多模态提示生成模块 MPGM。该模块利用 CLIP 作为文本语义编码器, 将离散的文本指令转化为连续的高维语义提示向量 P_{sem} 。这个语义向量承载了任务的全局定义, 充当了后续动态路由过程中的语义锚点。

编码器包含 4 个层级, 旨在逐步提取深层抽象特征。每个层级堆叠了若干 Transformer Block, 用于捕捉图像的局部细节与长距离依赖。与 VP-Net 仅依赖视觉特征进行路由不同, MAG-Net 在编码器的每个层级嵌入了多模态引导路由模块 (Multi-modal Guided Routing Module, MGRM)。在第 l 个层级, MGRM 同时接收三组输入信号: 当前主干特征 F_l^{enc} 、下采样的视觉引导特征 F_{guide}^l 以及全局语义提示 P_{sem} 。MGRM 作为一个智能的“调度中心”, 通过交叉注意力或特征拼接的方式, 融合底层的视觉纹理信息与高层的语义任务指令, 生成像素级的门控权重。这些权重动态地激活特定的专家网络组合, 从而对特征进行针对性的处理。通过引入 P_{sem} , MGRM 能够有效消除仅靠视觉特征难以区分的歧义, 确保特征被路由至语义上正确的专家路径, 实现了比 VP-Net 更彻底的任务解耦。层级间的下采样操作采用 Pixel-Unshuffle, 以在降低分辨率的同时保留完整的通道信息。

解码器与图像重建解码器结构与 VP-Net 保持一致, 包含 4 个对称的层级。由于编码阶段的 MGRM 已经完成了基于语义的任务解耦与特征增强, 解码阶段主要负责利用这些纯净的特征恢复空间细节。因此, 解码器采用标准的共享参数 Transformer Block, 未引入额外的路由机制。解码器通过跳跃连接 (Skip Connections) 融合编码器传递的多尺度特征, 并通过 Pixel-Shuffle 操作逐步恢复图像的空间分辨率。最终, 网络输出残差图像 I_{res} , 并与经双线性插值上采样的输入 I_{LR} 相加, 得到最终的超分结果 I_{SR} :

$$I_{\text{SR}} = I_{\text{res}} + \text{Upsample}(I_{\text{LR}}). \quad (4.1)$$

综上所述, MAG-Net 通过在骨干网络中无缝集成文本语义先验, 将视觉感知和高级语义信息相结合, 构建了一个具备认知能力的一体化图像修复框架。

4.2.2 多模态提示生成模块

为了向网络提供精确且对任务敏感的语义引导,需要将离散的自然语言描述转化为能够与视觉特征进行交互的连续嵌入向量。然而,直接使用预训练语言模型(如 BERT 或 CLIP)输出的特征往往存在两个问题:一是领域偏差,通用大模型对特定遥感或医学术语的理解可能不够细粒度;二是模态隔离,纯文本特征无法感知当前输入图像的具体状态(如噪声水平或纹理复杂度)。为此,本文设计了多模态提示生成模块(MPGM),引入了字典学习(Dictionary Learning)的思想。

MPGM 的处理流程如图 4.2 所示,包含视觉-文本特征提取、跨模态特征调制以及基于字典的提示重构三个阶段。




图 4.2 多模态提示生成模块示意图

视觉-语言特征提取

首先,对于描述任务属性的文本指令 T ,本文利用预训练的 CLIP 文本编码器提取其高维语义特征 $F_{\text{text}} \in \mathbb{R}^{D_t}$ 。与此同时,为了确保生成的提示能适应当前的图像内容,本文提取图像的视觉上下文。通过两个轻量级的卷积网络 $\mathcal{E}_{\text{LR}}$ 和 $\mathcal{E}_{\text{HR}}$ 分别提取低分辨率模型输入 I_{LR} 和高分辨率引导图 I_{HR} 的浅层特征,并通过通道拼接与 1×1 卷积融合操作获得联合视觉特征 $F_{\text{vis}} \in \mathbb{R}^{C \times H \times W}$:

$$F_{\text{vis}} = \mathcal{F}_{\text{fuse}}(\text{Concat}(\mathcal{E}_{\text{LR}}(I_{\text{LR}}), \mathcal{E}_{\text{HR}}(I_{\text{HR}}))), \quad (4.2)$$

这使得模块在处理不同图像时能够具有自适应的感知能力。

跨模态特征调制

为了将显式的语义指令注入到底层的视觉特征中, 本文采用特征线性调制 (FiLM) 机制。具体而言, 利用两个全连接层从文本特征 F_{text} 中预测出缩放系数 γ 和平移系数 β , 对视觉特征 F_{vis} 进行通道级的仿射变换:

$$F_{\text{mix}} = (1 + \gamma(F_{\text{text}})) \odot F_{\text{vis}} + \beta(F_{\text{text}}), \quad (4.3)$$

其中, $\odot$ 表示逐元素乘法, 公式中的 1 代表残差连接, 保证了视觉信息的完整传递。经过这一步, 生成的 F_{mix} 既包含了图像的空间纹理信息, 也被赋予了明确的任务语义倾向。

基于字典的提示重构

为了获得更加紧凑且适用于 GISR 任务的提示表示, 本文不再直接使用混合特征, 而是将其作为一个查询信号, 去检索一组可学习的语义锚点。本文预定义了一个任务无关的共享提示字典 $\mathcal{D} = \{\mathbf{d}_1, \mathbf{d}_2, \dots, \mathbf{d}_K\}$, 其中 $\mathbf{d}_k \in \mathbb{R}^D$ 为第 k 个潜在的语义原子, K 为原子总数。本文将 F_{mix} 进行全局平均池化得到向量 $\mathbf{z}$, 并通过一个线性分类器预测其在字典上的注意力分布 (即当前样本属于哪种潜在任务模式的概率):

$$\mathbf{w} = \text{Softmax}(\mathbf{W}_p \mathbf{z}) \in \mathbb{R}^K. \quad (4.4)$$

最终的语义提示 P_{sem} 由字典原子加权组合而成:

$$P_{\text{sem}} = \sum_{k=1}^K w_k \mathbf{d}_k. \quad (4.5)$$


这种设计即是一种软聚类过程, 模型自动学习从复杂的视觉-文本混合空间到一组纯净的任务基向量的映射。由此生成的 P_{sem} 既具有文本赋予的语义指向性, 又经过了图像内容的校准, 为后续的动态路由提供了鲁棒的先验信号。

4.2.3 融合多模态提示的动态路由模块

在第三章中, 本文提出了视觉感知路由模块, 通过感知引导图像的纹理和边缘信息来实现任务特征的物理解耦。然而, 正如引言所述, 仅依靠视觉特征容易产生歧义。为了解决这一问题, 本文将多模态提示生成模块生成的语义提示 P_{sem}

引入到路由决策中, 设计了融合多模态提示的动态路由模块 (Multi-modal Guided Routing Module, MGRM)。

如图 4.3 所示, MGRM 在架构上继承了 VPRM 的稀疏门控混合专家设计, 保留了混合专家组和稀疏分发与聚合机制。其核心改进在于门控网络的输入特征构造, 从单纯的视觉感知升级为视觉-语义联合感知。



在编码器的第 l 层级, MGRM 接收三路输入: 主干特征 F_l 、引导特征 F_{guide} 以及语义提示向量 P_{sem} 。与 VPRM 仅拼接 F_l 和 F_{guide} 不同, MGRM 采用了一种级联融合策略来生成门控信号:

首先, 主干特征与引导特征在通道维度拼接, 并经过一个 1×1 卷积层进行初步融合, 得到视觉上下文特征 $F_{\text{vis}'}$:

$$F_{\text{vis}'} = \text{Conv}_1([\text{Concat}(F_l, F_{\text{guide}})]). \quad (4.6)$$

随后, 为了将全局语义信息注入到局部门控决策中, 本文将语义提示向量 P_{sem} 在空间维度上进行广播, 使其尺寸扩充为与 $F_{\text{vis}'}$ 一致, 即 $P_{\text{sem}} \in \mathbb{R}^{B \times C \times H \times W}$ 。扩充后的语义提示与视觉上下文特征再次拼接, 并通过第二层卷积进行深度融合:

$$F_{\text{gate}} = \text{Conv}_2([\text{Concat}(F_{\text{vis}'}, P_{\text{sem}})]). \quad (4.7)$$

通过引入 P_{sem} , 门控网络不仅能感知像素局部的纹理差异 (由 F_{guide} 提供), 还能明确知晓当前任务的全局定义 (由 P_{sem} 提供)。例如, 在处理深度图超分任务时, 即便某些区域的纹理与 MRI 图像相似, 由于 P_{sem} 中包含了明确的“Depth Image”的语义编码, 门控网络依然能够抑制磁共振超分相关专家的激活, 强制将特征路由至负责深度图超分的专家。

最后, 融合后的特征 F_{gate} 经过激活函数调制, 并与其自身产生的注意力图相乘 (类似 GLU 门控线性单元结构), 生成最终用于预测路由分数的像素级特征向量 f_{gate} :

$$f_{\text{gate}} = \text{Conv}_3(\text{GELU}(F_{\text{gate}}) \odot F_{\text{vis}}'). \quad (4.8)$$

基于该特征, 本文沿用第三章所述的带噪声 Top-K 门控机制, 计算每个像素分配给各个专家的权重, 并进行稀疏分发:

$$G(f_{\text{gate}}) = \text{Softmax}(\text{TopK}(f_{\text{gate}} W_g + \text{Noise})). \quad (4.9)$$

通过这种设计, MGRM 实际上构建了一个条件概率模型 $P(\text{Expert} | \text{Visual}, \text{Semantic})$ 。相较于 VP-Net 的 $P(\text{Expert} | \text{Visual})$, MGRM 在决策时引入了额外的语义条件变量, 大大降低了路由选择的不确定性, 实现了更精准、更鲁棒的一体化任务解耦。

4.3 实验设置

为了公平评估 MAG-Net 在一体化 GISR 任务中的性能, 本章的实验设置与第三章保持一致: 将 MAG-Net 在全色锐化、深度图超分以及磁共振图像超分三个任务上进行了统一的训练与评估。

4.3.1 数据集与评测指标

本章沿用了第三章所述的三个标准数据集: (1) 全色锐化使用 QuickBird、WorldView-4 和 GaoFen-1 卫星数据集 [70], 评估指标包括 PSNR、SAM 和 ERGAS; (2) 深度图超分采用 NYU v2 RGB-D 数据集 [71], 主要评估指标为 RMSE; (3) 磁共振图像超分基于 BrainTS 数据集, 使用 PSNR 和 SSIM 进行评价。所有数据集的预处理方式、划分比例以及实验的超分倍率 (全色锐化 4 $\times$, 深度图 4 $\times$ /8 $\times$ /16 $\times$, MRI 2 $\times$ /4 $\times$ /8 $\times$) 均与前章一致。

4.3.2 实验细节

MAG-Net 基于 PyTorch 框架实现, 并在单块 NVIDIA RTX 3090 GPU 上进行训练。训练策略包括优化器选择、初始学习率及其衰减策略、批次大小以及总训练

轮次, 均与 VP-Net 的实验配置保持一致。在一体化联合训练过程中, 本文同样采用了基于最小数据集长度对齐的策略, 并混合所有任务的数据进行随机采样, 以确保模型能够均衡地学习多种任务特性。与 VP-Net 唯一的区别在于, MAG-Net 在输入端额外接收了任务描述文本, 并利用预训练的 CLIP 模型提取语义特征。

4.4 实验结果

4.4.1 对比实验

一体化方法对比

本文将 MAG-Net 与目前领先的一体化图像复原方法进行了比较, 包括 AirNet [58]、TransWeather [73]、PromptIR [3]、GridFormer [72]、CAPTNet [74] 和 AdaIR [75]。这些方法大多基于通用的 Encoder-Decoder 架构或 Transformer 结构, 旨在通过单一网络权重处理多种退化类型 (如去雨、去噪、去雾)。

为了将这些主要针对 RGB 图像 (3 通道) 设计的通用模型适配到 GISR 任务中, 必须解决输入维度不一致的问题。GISR 的三个子任务具有完全不同的输入数据结构: 磁共振超分输入为 2 通道 (单通道的引导图和单通道的目标图), 深度图超分为 4 通道 (3 通道的引导图和单通道的目标图), 而全色锐化则为 5 通道 (单通道的引导图和 4 通道的目标图)。直接将这些数据输入到期望 3 通道输入的预训练模型中是不可行的。为此, 本文在所有对比实验中均采用了与 VP-Net/MAG-Net 相同的多头输入适配策略: 为每个任务的特定通道数单独实例化一个浅层映射层, 将不同维度的原始输入统一映射到该模型的标准特征维度。这种做法确保了对比的公平性——所有模型都获得了完全相同的信息量, 且核心处理逻辑保持原样。

实验结果如表 4.1、表 4.2 和表 4.3 所示。在所有三个任务中, MAG-Net 均显著优于所有竞争对手。值得注意的是, PromptIR 虽然引入了视觉提示机制来处理不同任务, 但由于缺乏显式的多模态语义指引, 其未能充分利用 GISR 任务中丰富的先验知识 (如光谱特性或模态类型)。相比之下, MAG-Net 通过引入语义提示 P_{sem} , 在特征空间中构建了更明确的任务边界, 使得模型能够更精准地调用专家网络, 从而在处理复杂的异构任务时表现出更优越的性能。特别是与上一章的 VP-Net 相比, 引入语义增强后的 MAG-Net 在任务区分度较低的场景 (深度图

平滑区域与磁共振图像背景)中取得了更大的性能增益,进一步验证了视觉+语义双重驱动的有效性。

表 4.1 不同一体化方法在全色锐化任务上的对比结果,最优结果用粗体表示,次优结果用下划线表示

Method	Parameters	WV4			QB			GF1		
		PSNR↑	SAM↓	ERGAS↓	PSNR↑	SAM↓	ERGAS↓	PSNR↑	SAM↓	ERGAS↓
Gridformer	6.8M	40.49	1.42	1.19	47.72	0.96	0.70	45.59	0.98	0.97
Transweather	38.0M	39.54	1.67	1.39	46.26	1.14	0.80	43.99	1.22	1.18
CAPTNet	8.0M	41.10	1.38	1.15	47.92	0.94	0.68	48.94	0.70	0.77
AdaIR	10.2M	<u>43.46</u>	<u>1.06</u>	<u>0.85</u>	<u>49.90</u>	<u>0.75</u>	<u>0.54</u>	51.80	0.47	0.54
PromptIR	28.5M	43.34	1.08	0.88	49.76	0.76	0.55	<u>52.20</u>	<u>0.46</u>	<u>0.53</u>
MAGNet	5.1M	44.01	0.99	0.81	50.15	0.74	0.53	52.52	0.44	0.52




图 4.4 一体化设置下全色锐化任务的可视化对比与误差图

表 4.2 不同一体化方法在磁共振图像超分任务上的对比结果，最优结果用 粗体表示，次优结果用 下划线表示

Method	Parameters	2x		4x		8x	
		PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑
Gridformer	6.8M	42.15	0.9890	36.70	0.9662	33.64	0.9430
Transweather	38.0M	39.91	0.9821	36.25	0.9594	33.73	0.9332
CAPTNet	8.0M	40.43	0.9872	35.05	0.9573	32.09	0.9249
AdaIR	10.2M	<u>44.27</u>	<u>0.9928</u>	38.92	0.9780	35.56	<u>0.9585</u>
Restormer	25.3M	43.77	0.9896	38.03	0.9688	34.87	0.9491
PromptIR	28.5M	44.16	0.9926	<u>38.97</u>	<u>0.9781</u>	<u>35.58</u>	0.9582
MAGNet	5.1M	44.64	0.9928	39.21	0.9786	35.69	0.9679




图 4.5 一体化设置下磁共振图像超分任务的可视化对比与误差图

表 4.3 不同一体化方法在深度图超分任务上的对比结果，最优结果用粗体表示，次优结果用下划线表示

Method	Parameters	X4 RMSE↓	X8 RMSE↓	X16 RMSE↓
Gridformer	6.8M	1.67	3.04	5.72
Transweather	38.0M	2.97	4.14	6.20
CAPTNet	8.0M	1.64	2.88	5.13
AdaIR	10.2M	1.53	2.79	5.09
Restormer	25.3M	1.58	2.85	4.97
PromptIR	28.5M	<u>1.48</u>	<u>2.69</u>	<u>4.89</u>
MAGNet	5.1M	1.29	2.47	4.45




图 4.6 一体化设置下深度图超分任务的可视化对比与误差图

单任务方法对比

为了验证 MAG-Net 在特定领域是否也能达到甚至超越专用模型的水平，本文将 MAG-Net 分别与全色锐化、磁共振超分和深度图超分领域的先进单任务模型（SOTA）进行了对比。

全色锐化任务：如表 4.4 所示，本文将 MAG-Net 与包括 AWFLN [76]、DISPNet [77]、LAGConv [78]、M3DNet [79]、FusionMamba [4] 和 Dif-Pan [5] 在内的经典及最新深度学习方法进行了比较。尽管这些方法是专门为全色锐化

任务设计并针对特定光谱特性进行了优化的，MAG-Net 依然在所有三个数据集（WorldView-4, QuickBird, GaoFen-1）上取得了具有竞争力的表现。具体而言，MAG-Net 在保持光谱保真度（SAM）和空间细节恢复（ERGAS）方面表现优异，这得益于其强大的 Transformer 骨干网络以及通过语义提示明确激活的锐化感知专家模块。图 4.7 的可视化结果进一步显示，MAG-Net 生成的图像在边缘清晰度和光谱一致性上均优于许多现有方法，有效避免了常见的光谱扭曲现象。

表 4.4 不同单任务方法在全色锐化任务上的对比结果，最优结果用粗体表示，次优结果用下划线表示

Method	WV4			QB			GF1		
	PSNR↑	SAM↓	ERGAS↓	PSNR↑	SAM↓	ERGAS↓	PSNR↑	SAM↓	ERGAS↓
AWFLN	42.13	1.23	0.98	49.14	0.82	0.60	49.70	0.62	0.64
DISPNet	40.79	1.43	1.15	48.18	0.93	0.70	46.61	0.86	0.84
LAGConv	41.54	1.33	1.07	47.89	0.96	0.71	47.66	0.79	0.79
M3DNet	42.27	1.20	0.97	49.45	0.80	0.58	49.80	0.62	0.64
FusionMamba	42.84	1.15	0.92	49.50	0.81	0.59	50.79	0.55	0.60
DifPan	<u>43.89</u>	<u>1.03</u>	<u>0.83</u>	50.22	0.72	0.53	<u>52.33</u>	<u>0.46</u>	0.51
MAGNet	44.01	0.99	0.81	<u>50.15</u>	<u>0.74</u>	<u>0.53</u>	52.52	0.44	<u>0.52</u>




图 4.7 单任务设置下全色锐化任务的可视化对比与误差图

磁共振图像超分任务：在医学图像领域，本文将 MAG-Net 与 MGDUN [8]、DuDoNet [44]、MINet [80]、MASA [81]、McMRSR [82] 和 SANet [10] 等专用模型进行了对比。表 4.5 展示了定量评估结果。MAG-Net 在 PSNR 和 SSIM 指标上持续领先，特别是在高倍率（ $4\times$ 和 $8\times$ ）下优势更为明显。医学图像通常具有复杂的解剖结构且对细节丢失极为敏感，MAG-Net 通过语义提示准确识别出 MRI 任务特征，并动态调用能够捕捉精细纹理的专家网络，从而实现了更高质量的解剖结构重建。图 4.8 的误差图显示，MAG-Net 的重建结果与 Ground Truth 之间的残差最小，有效抑制了伪影的产生。

表 4.5 不同单任务方法在磁共振图像超分任务上的对比结果，最优结果用粗体表示，次优结果用下划线表示

Method	2x		4x		8x	
	PSNR↑	SSIM↑	PSNR↑	SSIM↑	PSNR↑	SSIM↑
MGDUN	40.97	0.9893	35.34	0.9632	32.61	0.9361
MADUNet	38.94	0.9843	34.09	0.9548	30.18	0.9114
MINet	38.84	0.9788	35.62	0.9625	32.38	0.9335
MASA	40.37	0.9883	34.93	0.9590	30.41	0.8954
McMRSR	40.96	0.9893	35.20	0.9596	30.55	0.8985
SANet	42.36	0.9881	36.56	0.9583	33.53	0.9419
DuDoNet	<u>44.96</u>	<u>0.9919</u>	<u>38.99</u>	<u>0.9744</u>	<u>35.43</u>	<u>0.9533</u>
MAGNet	45.03	0.9934	39.02	0.9780	35.62	0.9580




图 4.8 单任务设置下磁共振图像超分任务的可视化对比与误差图

深度图超分任务：针对深度图超分，本文选取了 GeoDSR [83]、DAGF [84]、AHMF [85]、DCTNet [86]、DKN [87] 和 SGNet [7] 作为对比基准。由于深度图具有分段平滑的特性，且边缘信息的保持至关重要。如表 4.6 所示，MAG-Net 在 RMSE 指标上取得了最低的误差，表明其恢复的深度值最接近真实值。这主要归功于 MAG-Net 的多模态引导机制，它不仅利用了高分辨率 RGB 图像作为结构引导，还通过语义提示强化了模型对深度图几何特性的理解，使其能够更好地区分边缘与平滑区域。图 4.9 的可视化结果表明，MAG-Net 生成的深度图边缘锐利且内部平滑，显著减少了以往方法中常见的模糊和锯齿效应。

表 4.6 不同单任务方法在深度图超分任务上的对比结果，最优结果用粗体表示，次优结果用下划线表示

Method	4x RMSE↓	8x RMSE↓	16x RMSE↓
GeoDSR	1.42	2.62	4.86
DAGF	1.36	2.87	6.06
AHMF	1.40	2.89	5.64
DCTNet	1.59	3.16	5.84
DKN	1.62	3.26	6.51
FDKN	1.86	3.58	6.69
SGNet	1.10	2.44	<u>4.77</u>
MAGNet	<u>1.29</u>	<u>2.47</u>	4.45




图 4.9 单任务设置下深度图超分任务的可视化对比与误差图

综上所述, MAG-Net 不仅是一个通用的一体化框架, 其在各个子任务上的表现也接近甚至超越各领域的专用 SOTA 模型。这证明了通过引入多模态语义提示, 通用的骨干网络完全有能力学习到高度专业化的任务表征, 同时具有通用性和专业性。

4.4.2 消融实验

为了验证 MAG-Net 中各个核心组件的有效性以及不同设计选择对模型性能的影响, 本文进行了详细的消融实验。

MPGM 与 MGRM 的有效性

为了探究多模态提示生成模块 MPGM 和多模态引导路由模块 MGRM 对模型性能的贡献, 本文设计了以下几种变体进行对比, 实验结果如表 4.7 所示, 需要解释的是:

1. w/o MPGM & w/o MGRM: 移除 MPGM 和 MGRM, 退化为通过简单的参数共享处理所有任务的静态 Backbone 网络。
2. w/ MPGM & w/o MGRM: 仅保留 MPGM 生成语义提示, 将其直接注入到网络中, 但不使用动态路由机制即所有任务仍共享同一套参数。
3. w/o MGRM & w/ MGRM: 仅保留 MGRM 的动态路由结构, 但不引入语义提示 P_{sem} , 仅依赖视觉特征 F_{guide} 进行路由决策。需要强调的是, 这一配置(表 4.7 中的第三行)等同于本文在第三章中提出的 VP-Net。
4. w/ MPGM & w/MGRM: 同时包含 MPGM 和 MGRM, 利用语义增强的动态路由进行任务解耦即 MAG-Net。

表 4.7 不同模块 (MPGM 与 MGRM) 消融实验结果分析

Module		Pansharpening			MR Image SR			Depth Image SR		
MPGM	MGRM	WV4	QB	GF1	2×	4×	8×	4×	8×	16×
×	×	43.68	49.94	51.60	44.32	38.92	35.29	1.50	2.79	5.12
✓	×	<u>43.83</u>	<u>50.09</u>	<u>52.34</u>	<u>44.46</u>	<u>39.16</u>	<u>35.35</u>	<u>1.41</u>	<u>2.63</u>	<u>4.75</u>
×	✓	43.71	50.00	51.71	44.13	38.96	35.31	1.47	2.69	4.88
✓	✓	44.01	50.15	52.52	44.64	39.21	35.60	1.29	2.47	4.45

从表 4.7 可以观察到:

- 与静态的 **Baseline** 相比，引入动态路由机制（**VP-Net**，第三行）在所有任务上均带来了性能提升，证明了任务解耦的必要性。
- 然而，仅依赖视觉引导的 **VP-Net** 在某些复杂场景下的提升有限。相比之下，引入 **MPGM**（第二行）虽然没有使用路由，但通过语义提示给予了网络一定的任务先验，性能优于 **Baseline**。
- 完整的 **MAG-Net**（第四行）取得了最佳性能。与第三行（**VP-Net**）的直观对比尤为关键：在引入 **MPGM** 将语义信息注入路由过程后，模型在全色锐化、**MRI SR** 和 **Depth SR** 任务上分别获得了进一步的性能增益（例如在 **MRI** 任务上 **PSNR** 提升了约 0.25 dB）。这有力地证明了 **VP-Net** 存在的视觉歧义性问题得到了有效缓解，显式的语义提示 P_{sem} 成功指导了门控网络做出更准确的决策，激活了更适配的专家路径，从而突破了纯视觉感知的性能瓶颈。

任务组合消融

为了探究多任务联合训练带来的收益(即正向迁移)以及任务间的相互影响，本文在表 4.8 中比较了单任务训练与不同任务组合的联合训练性能。

表 4.8 不同任务组合（Task P, M, D）消融实验结果分析

Task			Pansharpening			MR Image SR			Depth Image SR		
P	M	D	WV4	QB	GF1	2×	4×	8×	4×	8×	16×
✓	×	×	43.73	49.89	51.98	—	—	—	—	—	—
×	✓	×	—	—	—	45.03	39.02	35.62	—	—	—
×	×	✓	—	—	—	—	—	—	1.21	2.40	4.39
✓	✓	×	<u>44.01</u>	50.00	52.41	<u>44.88</u>	<u>39.25</u>	35.66	—	—	—
✓	×	✓	44.09	<u>50.05</u>	52.59	—	—	—	1.28	2.48	4.50
×	✓	✓	—	—	—	44.83	39.28	35.70	<u>1.27</u>	<u>2.47</u>	4.48
✓	✓	✓	<u>44.01</u>	50.15	<u>52.52</u>	44.64	39.21	35.60	1.29	<u>2.47</u>	<u>4.45</u>

实验结果表明，任务间的联合训练并非总是带来正向收益：

- 单任务训练 (Single-Task): 作为基准，模型专注于单一分布的数据。
- 两两组合训练 (Task Pairs): 本文发现某些任务组合（如 **Depth + MRI**）由于模态差异巨大且缺乏语义桥梁，在没有良好解耦的情况下甚至会出现严重的负迁移（性能低于单任务模式）。

- 一体化训练: 得益于 MAG-Net 强大的语义解耦能力, 在联合所有三个任务进行训练时, 模型不仅未受负迁移影响, 反而在所有任务上都超越了单任务基准。这说明 MAG-Net 成功利用了不同任务间的高层语义关联 (如结构一致性), 实现了“互助互利”的正向知识迁移。

多模态提示消融

为了验证 MPGM 中视觉+文本多模态提示设计的合理性, 本文对比了仅使用文本提示、仅使用图像提示即视觉特征以及两者结合的情况。

表 4.9 Text 与 Image 对联合任务性能的消融实验结果分析

Modality		Pansharpening			MR Image SR			Depth Image SR		
Text	Image	WV4	QB	GF1	2×	4×	8×	4×	8×	16×
×	×	43.81	50.01	50.73	44.19	39.02	35.56	1.47	2.72	4.91
✓	×	43.74	50.17	52.31	44.10	38.92	35.57	<u>1.46</u>	2.75	<u>4.84</u>
×	✓	43.73	50.09	<u>52.43</u>	<u>44.22</u>	<u>39.04</u>	35.61	1.48	<u>2.68</u>	4.91
✓	✓	44.01	<u>50.15</u>	52.52	44.64	39.21	<u>35.60</u>	1.29	2.47	4.45

结果如表 4.9 所示:

- Text Only: 仅利用 CLIP 提取的文本特征能提供较好的全局任务区分度, 但在处理图像特有的退化 (如不同程度的噪声) 时适应性较差。
- Image Only: 仅利用图像特征能感知局部纹理, 但缺乏明确的任务目标指引, 容易在纹理相似的任务间产生混淆。
- Text + Image (MAG-Net): 融合两者生成的 Prompt 既具备明确的语义指向性, 又拥有对输入内容的自适应感知能力, 因此取得了最优的性能表现。这一结果验证了本文在 MPGM 中引入跨模态特征调制 (FiLM) 及字典重构机制的有效性。

4.4.3 任务提示的可视化

为了直观地验证 MAG-Net 中生成的任务提示是否真正捕捉到了不同 GISR 任务的语义特征, 本文提取了 MPGM 输出的高维提示向量 P_{sem} , 并利用 t-SNE 技术将其投影到二维平面进行可视化分析。这一可视化实验旨在回答两个核心问题:

- 第一，对于不同 GISR 任务，生成的提示是否具有显著的区分度？
- 第二，对于同一任务下的不同细粒度属性（如不同的超分倍率），提示能否体现出相应的差异性？

图 4.10 展示了 MAG-Net 在 3 个 GISR 任务生成的提示分布情况。从图中可以清晰地观察到，属于同一大类任务的提示向量紧密聚集在一起，而不同任务类别的提示簇之间呈现出显著的分离态势。具体而言，Pansharpening（蓝色系）、Depth SR（红色系）和 MRI SR（绿色系）三个任务的提示分别占据了特征空间的不同区域，且边界清晰。这一结果有力地证明了 MPGM 成功地将自然语言描述中的离散语义映射为了连续且具有判别力的特征表示，使得模型能够明确区分具有不同物理属性和恢复目标的任务，从而为后续 MGRM 中的精确路由提供了可靠的证据。这种基于语义的任务解耦能力，正是 MAG-Net 能够克服 VP-Net 视觉歧义性问题的关键所在。




图 4.10 MAG-Net 在所有数据集的所有 GISR 子任务上的提示表示 t-SNE 可视化

进一步地，为了探究提示对细粒度任务属性的敏感性，本文在图 4.11 中专门展示了 MRI 图像超分任务在不同缩放倍率（ $2\times$ 、 $4\times$ 、 $8\times$ ）下的提示分布。可视化结果显示，即便是在同一任务模态内部，对应于不同缩放因子的提示也呈现出了有序的聚类结构。 $2\times$ 、 $4\times$ 和 $8\times$ 的提示分别形成了独立的条带状子簇，这表明 MAG-Net 生成的提示不仅编码了高层的任务类别信息（Task Type），还敏锐地捕捉到了底层的操作参数（。这种细粒度的语义感知能力使得模型能够根据具

体的退化程度动态调整专家的激活模式,从而在统一框架下实现对多尺度任务的精细化处理。

综上所述, t-SNE 可视化实验从特征流形空间的角度证实了 MPGM 的有效性:生成的提示向量既具有类间可分性,又具备类内紧凑性。




图 4.11 MAG-Net 在磁共振图像超分任务中不同超分比率下的提示表示 t-SNE 可视化

4.5 本章小结

本章针对上一章 VP-Net 模型中存在的视觉歧义性与语义缺失问题,提出了一种融合多模态语义提示的一体化引导式图像超分方法 (MAG-Net)。该方法在继承视觉感知动态路由架构的基础上,引入了文本语义作为显式的任务先验,构建了从感知到认知的完整映射。

本章的核心创新点在于设计了多模态提示生成模块 MPGM 与语义增强的动态路由模块 MGRM。MPGM 利用预训练的视觉-语言模型将离散的任务描述转化为连续的高维语义提示,并通过字典学习机制对提示进行重构,使其兼具明确的语义指向性与图像内容适应性。MGRM 则将这些语义提示作为全局条件注入到门控网络中,与底层视觉特征深度融合,从而指导模型在该像素级和任务级做出更精准的专家选择。这种视觉+语义的双重驱动机制有效消除了仅靠纹理特征难以区分的任务边界,实现了更彻底的任务解耦。

实验结果表明, MAG-Net 在全色锐化、深度图超分及磁共振图像超分三个子任务上, 不仅在一体化设置下显著优于现有通用模型及 VP-Net, 而且在与各领域最先进的专用模型对比中也展现出了卓越的性能。消融实验进一步验证了引入文本语义提示对于缓解负迁移、促进正向知识共享的关键作用。MAG-Net 的成功探索证明了在高层语义指导下, 单一模型完全有能力在处理异构多模态任务时兼顾通用性与专业性, 为未来构建更智能、更通用的多模态图像复原系统提供了新的思路。

第五章 一体化引导式图像超分系统

5.1 引言

在前两章中，本文分别提出了基于视觉感知动态路由的 VP-Net 和融合多模态语义提示的 MAG-Net，从理论层面和实验层面验证了一体化引导式图像超分方法在磁共振图像超分、全色锐化及深度图超分等任务上的有效性。然而，这些先进的深度学习模型主要以代码脚本的形式存在，依赖复杂的命令行操作和环境配置，这对于缺乏深度学习背景的垂直领域专家与从业者——如医学影像医生、遥感测绘工程师以及自动驾驶研发人员来说，存在着较高的使用门槛。

为了弥合先进算法与行业应用之间的鸿沟，赋能垂直领域的高质量图像获取，本章基于 B/S (Browser/Server) 架构，设计并实现了一个面向多领域专家的一体化引导式图像超分演示系统。该系统集成了前文提出的核心算法模型，利用 Python Flask 框架搭建后端服务，结合 Bootstrap 前端框架构建直观的交互界面。系统通过封装复杂的模型推理过程，为不同领域的从业者提供了定制化的图像增强服务：协助医生获取更清晰的病灶细节，帮助测绘工程师获得高分辨率的卫星融合影像，以及为自动驾驶系统提供精细的深度感知信息。

本章将详细阐述该系统的需求分析、总体架构设计、功能模块实现以及开发环境配置。通过该系统的构建，旨在探索将一体化大模型技术转化为各行业生产力的工程实践方案。

5.2 需求分析

在开发本系统之前，本文深入调研了医学影像、遥感测绘及自动驾驶等领域的实际工作流，针对不同用户群体的核心痛点进行了详细的需求分析。本节将从功能性需求和非功能性需求两个维度进行阐述。

5.2.1 功能性需求

本系统的核心目标是为各垂直领域的专家提供一个零代码、即插即用的图像超分增强平台。根据不同行业用户的应用场景，具体功能需求如下：

面向多领域任务的场景化配置

系统需支持针对不同行业场景的定制化任务选择：

1. 医学影像增强：面向医学影像医生，支持导入低分辨率 MRI 扫描图像，通过超分算法重建高频纹理细节，辅助早期病灶筛查与诊断。
2. 遥感影像融合：面向遥感与测绘工程师，支持全色影像与多光谱影像的融合处理，生成高分辨率多光谱数据，服务于地物分类与环境监测。
3. 深度图增强：面向 3D 视觉与自动驾驶工程师，支持对低分辨率深度传感器数据进行上采样，恢复精细的几何结构信息，提升 SLAM 建图与避障精度。

此外，系统需屏蔽复杂的模型超参数，仅保留倍率因子（ $2\times, 4\times, 8\times, 16\times$ ）等业务相关选项。

交互式可视化与对比分析

专家用户往往需要对处理结果进行严格的质量评估。系统应提供直观的图像对比工具，支持“原始输入-算法输出”的实时切换或并排展示。特别地，针对医学和遥感图像的大图浏览需求，需支持局部放大查看功能，以便医生观察微小病变或工程师确认地物边缘。同时，系统应提供 PSNR、SSIM 等客观指标作为参考，辅助用户判断图像质量。

工程化批量处理

在实际的自动驾驶路测数据处理或大区域遥感制图中，工程师通常需要处理海量数据。系统需支持以文件夹为单位的批量上传与自动化队列处理功能。用户只需指定输入目录，系统后台即可自动调度资源完成所有图像的增强处理，并按原目录结构导出，显著提升工程效率。

全流程历史追溯

考虑到医疗诊断的可追溯性与测绘成果的归档要求，系统需具备完整的历史记录功能。每一次图像处理任务的输入源、所选算法、参数配置、处理耗时及结果指标通过数据库持久化存储。用户可随时回溯过往的处理记录，复现实验结果或导出分析报告。

多用户隔离与数据安全

由于医学影像涉及患者隐私，遥感数据可能涉及地理信息安全，系统必须具备严格的用户认证与权限管理机制。采用隔离的会话管理，确保不同科室医生或不同项目组工程师的数据互不可见，保障行业数据的安全性。

5.2.2 非功能性需求

除了满足业务功能外，考虑到目标用户（医生、工程师）通常在高负荷环境下工作，系统还需满足以下非功能性指标：

极简操作与低学习成本

界面设计应遵循“少即是多”的原则，尽量减少非业务相关的干扰元素。操作流程应符合行业专家的直觉，例如采用医学影像常用的黑底风格或工程软件常见的布局，确保用户无需阅读手册即可上手使用。

高响应与实时反馈

对于大分辨率的遥感影像或 3D 深度图，处理过程可能较长。系统需提供精确的进度反馈机制（如进度条、剩余时间预估），避免用户产生焦虑。前端交互响应时间应控制在毫秒级，确保缩放、拖拽等操作的流畅性。

兼容性与易部署

考虑到医院内网环境或工程现场设备的多样性，系统应具备良好的跨平台兼容性。后端采用通用的 Python 环境，可部署在 Linux 服务器或高性能工作站上；前端基于标准 Web 技术，支持主流浏览器访问，无需在医生的诊断工作站或工程师的笔记本上安装额外客户端。

5.3 系统设计与实现

5.3.1 总体架构

本系统采用经典的 B/S 架构，如图 5.1 所示，系统整体自上而下划分为展示层、服务层、算法层和数据层四个核心层次。各层之间通过明确的接口进行通信，保证了系统的高内聚与低耦合：

展示层

直接面向终端用户，通过浏览器进行访问。采用响应式设计以适配不同尺寸的设备屏幕，并基于 Bootstrap UI 框架构建直观、易用的交互界面，提供图像上传、参数配置、结果可视化等功能。

服务层

作为系统的中枢神经，基于轻量级的 Python Flask 服务器实现。负责对外提供 RESTful API 接口以接收前端请求，并进行核心的业务逻辑处理与任务调度，向下驱动算法层进行推理计算。

算法层

系统的核心计算引擎，包含了精心设计的神经网络结构。该层集成了基于 PyTorch 框架实现的 MAG-Net 等一体化 AI 模型，负责执行具体的图像重建与增强任务。

数据层

负责系统数据的持久化存储与管理。采用 MySQL 数据库存储用户账户信息与历史任务元数据，同时利用文件系统和硬盘存储海量的输入输出图像文件。




图 5.1 一体化引导式图像超分系统总体分层架构图

5.3.2 功能模块设计与实现

根据需求分析与实际业务流程，本文将系统划分为三个核心功能模块：用户认证模块、交互式图像复原与可视化模块以及批量任务管理与历史追溯模块。本节将详细阐述各模块的设计思路与关键实现。

用户认证与权限管理模块

为了保障系统的安全性与数据隔离，系统实现了基于会话（Session）的用户认证机制。该模块主要包括用户登录、注销及会话状态保持功能。

1. 用户输入账号与密码后，前端通过 POST 请求将凭证发送至后端 /login 接口。后端验证通过后，生成唯一的 Session ID 并写入浏览器 Cookie，作为后续请求的身份标识。
2. 通过 Flask 的 login_required 装饰器对核心业务接口（如上传、处理）进行保护，未登录用户的请求将被拦截并重定向至登录页。



图 5.2 系统用户登录与认证界面

交互式图像复原与可视化模块

该模块是系统的核心交互界面，如图 5.3 所示，集成了任务配置、模型选择、图像上传、推理调度及结果对比分析的全流程功能，旨在为用户提供所见即所得的即时反馈体验。

1. 为了满足不同层次用户的需求，模块支持灵活的算法策略选择。用户既可以选择基于 MAG-Net 的“一体化通用模型”策略，体验语义提示驱动的多模态处理；也可以切换至“任务专用模型”策略，调用各领域的 SOTA 模型进行对比验证。前端通过 JavaScript 实现动态联动，根据所选策略自动隐藏或显示相应的模型选项及提示词输入框。
2. 当选择 MAG-Net 模型时，系统利用内置规则引擎，根据当前选择的任务类型和缩放倍率，自动生成符合模型输入的英文语义提示（例如“Pansharpening for satellite imagery, scale factor 4x”），极大降低了垂直领域专家的使用门槛。
3. 用户上传图像并点击处理后，前端通过 AJAX 异步调用后端核心推理接口。系统采用非阻塞式设计，在后端调用 Python 算法脚本（如 MAGNet.py）进行计算的同时，前端展示加载动画与进度条，确保界面的流畅性。
4. 推理完成后，模块提供专业的图像对比工具。支持并排模式以展示整体差异，以及“叠加模式 Overlay 或卷帘模式，允许用户通过拖动滑块在同一坐标系下

实时比对 LR 输入与 SR 输出的细节差异，辅助医生或工程师进行精细化质量评估。




图 5.3 交互式图像复原与可视化界面

批量任务管理与历史追溯模块

针对工程化应用场景，本模块提供了高效率的数据处理与归档能力。

1. 支持用户上传整个文件夹，系统后端遍历目录结构，建立任务队列，逐一调用算法模型进行处理，并将结果按原目录结构保存，大幅提高了大规模数据集的验证效率。




图 5.4 批量图像处理界面

2. 系统自动记录每次任务的元数据（任务 ID、类型、耗时、PSNR/SSIM 指标）。历史页面以列表形式展示过往实验，支持按时间排序与筛选，用户可随时点击查看某次实验的详细参数与结果图，满足了实验可复现性的要求。




图 5.5 历史操作记录界面

5.4 数据库设计

为了支持系统的用户管理、批量任务调度以及历史记录追溯功能，本系统设计了基于关系型数据库（MySQL）的数据存储方案。核心数据表包括用户表（users）、任务批次表（task_batches）以及系统日志表（system_logs）。

5.4.1 用户表设计

用户表主要用于存储系统用户的基本信息及认证凭据。考虑到系统需面向不同角色的用户（如管理员、医生、工程师），表中包含了角色字段以支持权限控制。表结构如表 5.1 所示。

表 5.1 用户信息表 (users)

字段名	类型	约束	说明
id	INT	PRIMARY KEY	用户 ID
username	VARCHAR(50)	UNIQUE, NOT NULL	用户名
password	VARCHAR(255)	NOT NULL	加密存储的密码
role	ENUM	NOT NULL	用户角色
name	VARCHAR(50)		真实姓名
created_at	TIMESTAMP	DEFAULT	创建时间
last_login	TIMESTAMP		最后登录时间

5.4.2 任务批次表设计

任务批次表是以目录为单位记录批量处理任务及其聚合状态的核心表。每一次批量上传操作都会生成一个唯一的批次号（Batch ID），系统通过该表追踪任务的处理进度及最终的质量指标（如平均 PSNR）。表结构如表 5.2 所示。

表 5.2 任务批次表 (task_batches)

字段名	类型	约束	说明
batch_id	VARCHAR(64)	PRIMARY KEY	批次号
user_id	INT	FOREIGN KEY	创建用户 ID
source_dir	VARCHAR(512)	NOT NULL	源文件目录
target_dir	VARCHAR(512)	NOT NULL	目标输出目录
task_type	ENUM	NOT NULL	任务类型
scale_factor	VARCHAR(10)		缩放倍率
status	ENUM		批次状态
avg_psnr	FLOAT		平均 PSNR
created_at	TIMESTAMP	DEFAULT	创建时间

5.4.3 系统日志表设计

系统日志表用于审计和追踪系统的关键操作或异常情况，确保系统的安全性与可维护性。表结构如表 5.3 所示。

表 5.3 系统日志表 (system_logs)

字段名	类型	约束	说明
id	BIGINT	PRIMARY KEY	日志 ID
user_id	INT	FOREIGN KEY	操作用户 ID
action	VARCHAR(50)	NOT NULL	操作动作
ip_address	VARCHAR(45)		客户端 IP
timestamp	TIMESTAMP	DEFAULT	发生时间

5.5 本章小结

本章主要介绍了一体化引导式图像超分演示系统的设计与实现。针对垂直领域专家在使用先进深度学习模型时面临的技术门槛与操作痛点，本章首先从功能性与非功能性两个维度进行了详细的需求分析，明确了系统需具备多领域场景化配置、交互式可视化对比、工程化批量处理及全流程历史追溯等核心能力。

在此基础上，本章提出并实现了一种基于 B/S 架构的系统解决方案。系统自上而下划分为展示层、服务层、算法层和数据层，实现了高内聚低耦合的分层设计。文中详细阐述了关键功能模块的实现细节：通过基于会话的用户认证机制保障了数据安全；设计了交互式图像复原模块，将 MAG-Net 模型的语义提示生成机制封装于后端，使用户能够通过简单的界面操作即可调用复杂的一体化算法；构建了批量任务管理模块，有效满足了工程场景下大规模数据的处理需求。此外，本章还给出了支撑系统运行的数据库设计方案。

该系统的成功构建，不仅验证了前文提出的一体化引导式图像超分算法（MAG-Net）在实际应用环境中的可行性与鲁棒性，也为医学影像、遥感测绘及自动驾驶等垂直领域的图像增强任务提供了一套零代码、高效率、可视化的工程实践参考，有效缩小了前沿 AI 技术与行业实际应用之间的鸿沟。

第六章 总结与展望

6.1 工作总结

传统引导式图像超分的单任务单模型封闭范式，既会造成训练推理的资源浪费，又难以挖掘各个任务之间的深层关联。本研究旨在构建一个一体化的网络模型，能同时处理全色锐化、深度图超分及磁共振图像超分这些引导式图像超分任务。从最初探索引入这一挑战，到提出基于纯视觉感知的解决方案，再到通过多模态语义增强突破瓶颈，并最终完成工程化系统的搭建，本文层层递进地形成了一套完整的理论与应用体系。具体工作总结如下：

首先，针对现有静态参数共享网络在多任务联合训练时容易发生的负迁移现象，即不同模态的数据分布差异导致网络参数更新方向冲突，本文提出了一种基于视觉感知动态路由的一体化网络架构（VP-Net）。该方法通过引入动态路由机制，根据输入引导图像的纹理、边缘等高频视觉特征，动态生成像素级的门控权重，从而为不同特征自适应地选择最优的专家处理路径。这种基于图像内容的物理隔离策略，在一定程度上缓解了多任务间的参数干扰，实现了优于传统静态共享模型的性能。然而，研究也揭示了仅依赖底层视觉特征存在的局限性：在面对纹理统计特性相似但语义任务截然不同的场景时（如平滑的深度图区域与 MRI 背景），路由模块容易产生混淆与歧义，导致特征被错误分发，限制了模型性能的进一步提升。

其次，为了克服纯视觉感知的语义盲区，本文提出了一种融合多模态语义提示的增强型网络（MAG-Net）。该模型在 VP-Net 的基础架构上实现了从感知到认知的跨越。通过设计多模态提示生成模块（MPGM），利用预训练的 CLIP 视觉-语言大模型将抽象的任务描述文本转化为富含语义的高维特征向量。这些语义向量作为显式的关键特征注入到动态路由网络中，与底层视觉特征共同指导门控决策。这种视觉感知 + 语义引导的双重驱动机制，不仅消除了任务识别的歧义性，还促进了跨任务的正向知识迁移。在全色锐化、深度图超分及磁共振超分三个标准数据集上的对比实验中，MAG-Net 展现出了卓越的性能，证明了在高层语义指导下，单一模型完全有能力在同时处理多种引导式超分任务时兼顾通用性与专业性。

最后,为了验证算法的实际应用价值并服务于垂直领域,本文设计并开发了一个基于 B/S 架构的一体化引导式图像超分演示系统。该系统以本文提出的 MAG-Net 为核心引擎,后端采用 Python Flask 框架实现高效的模型推理与任务调度,前端基于 Bootstrap 框架构建了符合行业专家操作习惯的交互界面。系统不仅实现了单张图像的实时上传、参数配置与可视化对比分析,还针对工程场景提供了文件夹级别的批量自动化处理与历史记录追溯功能。该系统的成功构建,有效降低了先进深度学习模型的使用门槛,使医学影像医生、测绘工程师等非 AI 背景的专业人士能够便捷地获取高质量的增强图像,为一体化超分技术在多元化行业的落地应用提供了切实可行的工程范例。

6.2 未来展望

尽管本文在多模态一体化引导式图像超分领域进行了较为深入的探索,并在算法精度与系统可用性方面取得了预期的成果,但受限于当前的研究条件与技术发展阶段,工作仍存在一定的局限性。展望未来,以下几个方向值得进一步挖掘与完善:

第一,探索摆脱对成对训练数据依赖的无监督学习范式。目前的 VP-Net 与 MAG-Net 均属于全监督学习模型,其优越性能的发挥在很大程度上依赖于大量配准的低分辨率-高分辨率图像对。然而,在真实的临床医学扫描或动态变化的遥感观测中,获取像对像素级对齐的真值数据常常由于设备限制或环境干扰而变得极为困难。未来的研究应致力于降低对高质量标注数据的依赖,尝试引入无监督学习、循环一致性生成对抗网络(CycleGAN)或基于自监督的掩码图像建模技术,直接利用非成对的真实数据进行训练。此外,结合近年来兴起的扩散模型(Diffusion Models),利用其强大的生成先验能力在无参考图像的情况下“想象”出合理的细节,将是提升模型在开放世界场景下泛化能力的重要途径。

第二,构建轻量化模型以适配端侧边缘计算。目前的 MAG-Net 为了在三个任务上均达到 SOTA 性能,采用了包含大量参数的 Transformer 骨干网络与多专家混合结构,导致计算开销较大,难以在资源受限设备上实时运行。而在自动驾驶车载终端、手持式医疗超声设备或星载边缘计算单元中,低延迟与低功耗是至关重要的指标。未来的工作将聚焦于模型的轻量化研究,通过知识蒸馏技术将大模型的知识迁移至轻量级学生网络,或者结合网络架构搜索(NAS)、模型剪枝与

量化技术,在尽可能保持一体化处理能力与精度的前提下,显著压缩模型体积与运算量,真正实现一体化多模态超分技术在各行业终端设备上的广泛部署与实时应用。

第三,深化文本语义交互的粒度与智能性。虽然 MAG-Net 成功引入了文本提示来辅助路由决策,但目前的交互形式仍较为初级,主要局限于预设的任务类别与倍率标签。随着多模态大语言模型(MLLM)技术的爆发,未来可以将更通用的语言理解能力融合到底层视觉网络中。不仅支持任务级别的宏观指令,更应支持细粒度的自然语言交互。例如,用户可以通过对话框输入“增强左侧血管的纹理细节但保持背景平滑”或“修复由于云层遮挡导致的模糊区域”,模型能够理解这些复杂的意图并精准地在特征图上执行相应的操作。这将推动图像超分工具从单一的“画质增强器”向具备理解与推理能力的“智能影像处理助手”演进。

参考文献

- [1] SHAZEER N, MIRHOSEINI A, MAZIARZ K, et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer[J]. arXiv preprint arXiv:1701.06538, 2017.
- [2] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//International Conference on Machine Learning. 2021: 8748-8763.
- [3] POTLAPALLI V, ZAMIR S W, KHAN S H, et al. Promptir: Prompting for all-in-one image restoration[J]. Advances in Neural Information Processing Systems, 2023, 36: 71275-71293.
- [4] PENG S, ZHU X, DENG H, et al. Fusionmamba: Efficient remote sensing image fusion with state space model[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-16.
- [5] CAO Z, CAO S, DENG L J, et al. Diffusion model with disentangled modulations for sharpening multispectral and hyperspectral images[J]. Information Fusion, 2024, 104: 102158.
- [6] WANG Y, HE X, DONG Y, et al. Cross-modality interaction network for pan-sharpening[J]. IEEE Transactions on Geoscience and Remote Sensing, 2024, 62: 1-16.
- [7] WANG Z, YAN Z, YANG J. Sgnet: Structure guided network via gradient-frequency awareness for depth map super-resolution[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 38. 2024: 5823-5831.
- [8] YANG G, ZHANG L, LIU A, et al. MGDUN: An interpretable network for multi-contrast MRI image super-resolution reconstruction[J]. Computers in Biology and Medicine, 2023, 167: 107605.
- [9] LEI P, HU L, FANG F, et al. Joint under-sampling pattern and dual-domain reconstruction for accelerating multi-contrast MRI[J]. IEEE Transactions on Image Processing, 2024, 33: 4686-4701.

- [10] FENG C M, YAN Y, YU K, et al. Exploring separable attention for multi-contrast MR image super-resolution[J]. IEEE Transactions on Neural Networks and Learning Systems, 2024, 35(9): 12251-12262.
- [11] CHAVEZ P, SIDES S C, ANDERSON J A, et al. Comparison of three different methods to merge multiresolution and multispectral data- Landsat TM and SPOT panchromatic[J]. Photogrammetric Engineering and Remote Sensing, 1991, 57(3): 295-303.
- [12] TU T M, HUANG P S, HUNG C L, et al. A fast intensity-hue-saturation fusion technique with spectral adjustment for IKONOS imagery[J]. IEEE Geoscience and Remote Sensing Letters, 2004, 1(4): 309-312.
- [13] LABEN C A, BROWER B V. Process for enhancing the spatial resolution of multispectral imagery using pan-sharpening[Z]. Google Patents, 2000.
- [14] GILLESPIE A R, KAHLE A B, WALKER R E. Color enhancement of highly correlated images. II. Channel ratio and “chromaticity” transformation techniques[J]. Remote Sensing of Environment, 1987, 22(3): 343-365.
- [15] NUNEZ J, OTAZU X, FORS O, et al. Multiresolution-based image fusion with additive wavelet decomposition[J]. IEEE Transactions on Geoscience and Remote Sensing, 2002, 37(3): 1204-1211.
- [16] BURT P J, ADELSON E H. The Laplacian pyramid as a compact image code[Z]// Readings in Computer Vision. Elsevier, 1987: 671-679.
- [17] DO M N, VETTERLI M. The contourlet transform: an efficient directional multiresolution image representation[J]. IEEE Transactions on Image Processing, 2005, 14(12): 2091-2106.
- [18] LI S, YANG B. A new pan-sharpening method using a compressed sensing technique[J]. IEEE Transactions on Geoscience and Remote Sensing, 2010, 49(2): 738-746.
- [19] BALLESTER C, CASELLES V, IGUAL L, et al. A variational model for P+ XS image fusion[J]. International Journal of Computer Vision, 2006, 69(1): 43-58.

- [20] ZHU X X, BAMLER R. A sparse image fusion algorithm with application to pan-sharpening[J]. IEEE Transactions on Geoscience and Remote Sensing, 2012, 51(5): 2827-2836.
- [21] PALSSON F, SVEINSSON J R, ULFARSSON M O. A new pansharpening algorithm based on total variation[J]. IEEE Geoscience and Remote Sensing Letters, 2013, 11(1): 318-322.
- [22] KOPF J, COHEN M F, LISCHINSKI D, et al. Joint bilateral upsampling[J]. ACM Transactions on Graphics, 2007, 26(3): 96–es.
- [23] HE K, SUN J, TANG X. Guided image filtering[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2012, 35(6): 1397-1409.
- [24] DIEBEL J, THRUN S. An application of markov random fields to range sensing[J]. Advances in Neural Information Processing Systems, 2005, 18.
- [25] FERSTL D, REINBACHER C, RANFTL R, et al. Image guided depth upsampling using anisotropic total generalized variation[C]//Proceedings of the IEEE International Conference on Computer Vision. 2013: 993-1000.
- [26] KIECHLE M, HAWE S, KLEINSTEUBER M. A joint intensity and depth co-sparse analysis model for depth map super-resolution[C]//Proceedings of the IEEE International Conference on Computer Vision. 2013: 1545-1552.
- [27] YANG J, YE X, LI K, et al. Color-guided depth recovery from RGB-D data using an adaptive autoregressive model[J]. IEEE Transactions on Image Processing, 2014, 23(8): 3443-3458.
- [28] PELED S, YESHURUN Y. Superresolution in MRI: application to human white matter fiber tract visualization by diffusion tensor imaging[J]. Magnetic Resonance in Medicine: An Official Journal of the International Society for Magnetic Resonance in Medicine, 2001, 45(1): 29-35.
- [29] MANJÓN J V, COUPÉ P, BUADES A, et al. Non-local MRI upsampling[J]. Medical Image Analysis, 2010, 14(6): 784-792.
- [30] WANG Y H, QIAO J, LI J B, et al. Sparse representation-based MRI super-resolution reconstruction[J]. Measurement, 2014, 47: 946-953.

- [31] LECUN Y, BOTTOU L, BENGIO Y, et al. Gradient-based learning applied to document recognition[J]. Proceedings of the IEEE, 2002, 86(11): 2278-2324.
- [32] VASWANI A, SHAZEER N, PARMAR N, et al. Attention is all you need[J]. Advances in Neural Information Processing Systems, 2017, 30.
- [33] YANG J, FU X, HU Y, et al. PanNet: A deep network architecture for pan-sharpening[C]//Proceedings of IEEE International Conference on Computer Vision. 2017: 5449-5457.
- [34] WANG Y, DENG L J, ZHANG T J, et al. SSconv: Explicit spectral-to-spatial convolution for pansharpening[C]//Proceedings of the 29th ACM International Conference on Multimedia. 2021: 4472-4480.
- [35] MARIVANI I, TSILIGIANNI E, CORNELIS B, et al. Multimodal deep unfolding for guided image super-resolution[J]. IEEE Transactions on Image Processing, 2020, 29: 8443-8456.
- [36] DENG X, DRAGOTTI P L. Deep coupled ISTA network for multi-modal image super-resolution[J]. IEEE Transactions on Image Processing, 2019, 29: 1683-1698.
- [37] YANG G, ZHOU M, YAN K, et al. Memory-augmented deep conditional unfolding network for pan-sharpening[C]//Proceedings of IEEE International Conference on Computer Vision. 2022: 1788-1797.
- [38] ZHAO M, MA M, LI X, et al. Deep unfolding network with spatial-spectral perception enhanced for pan-sharpening[C]//British Machine Vision Conference. 2024.
- [39] DO J, KIM S, YOUK G, et al. PAN-Crafter: Learning modality-consistent alignment for PAN-sharpening[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025: 4242-4252.
- [40] YUAN J, JIANG H, LI X, et al. Structure flow-guided network for real depth super-resolution[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 37. 2023: 3340-3348.

- [41] ZHANG S, PAN Z, LV Y, et al. Hierarchical edge refinement network for guided depth map super-resolution[J]. IEEE Transactions on Computational Imaging, 2024, 10: 469-478.
- [42] WANG Z, YAN Z, WU Y, et al. Multi-order matching network for alignment-free depth super-resolution[J]. arXiv preprint arXiv:2511.16361, 2025.
- [43] ZHANG J, ZHAO L, ZHANG J, et al. Joint deep-unfolding optimization learning for depth map arbitrary-scale super-resolution[J]. IEEE Transactions on Multimedia, 2025, 27: 9478-9491.
- [44] LEI P, FANG F, ZHANG G, et al. Deep unfolding convolutional dictionary model for multi-contrast MRI super-resolution and reconstruction[C]//Proceedings of the Thirty-Second International Joint Conference on Artificial Intelligence. 2023: 1008-1016.
- [45] LEI P, FANG F, ZHANG G, et al. Decomposition-based variational network for multi-contrast MRI super-resolution and reconstruction[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 21296-21306.
- [46] ZHOU M, YAN K, PAN J, et al. Memory-augmented deep unfolding network for guided image super-resolution[J]. International Journal of Computer Vision, 2023, 131(1): 215-242.
- [47] LI G, ZHAO L, SUN J, et al. Rethinking multi-contrast mri super-resolution: Rectangle-window cross-attention transformer and arbitrary-scale upsampling[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2023: 21230-21240.
- [48] LI G, RAO C, MO J, et al. Rethinking diffusion model for multi-contrast mri super-resolution[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 11365-11374.
- [49] ZHAO A, SONG Z, XU Y, et al. Mamba-enhanced large-window transformer for multi-contrast brain MRI super-resolution[C]//2025 IEEE International Conference on Bioinformatics and Biomedicine. 2025: 5795-5802.

- [50] CONDE M V, GEIGLE G, TIMOFTE R. Instructir: High-quality image restoration following human instructions[C]//European Conference on Computer Vision. 2024: 1-21.
- [51] WANG B, QIN B, LI J, et al. All-in-One Image Restoration via Causal-Deconfounding Wavelet-Disentangled Prompt Network[J]. arXiv preprint arXiv:2603.03839, 2026.
- [52] DONG G, LI C, REN C, et al. Learning Domain-Aware Task Prompt Representations for Multi-Domain All-in-One Image Restoration[J]. arXiv preprint arXiv:2603.01725, 2026.
- [53] CUI Y, LIU M, SU X, et al. Frequency-Prompted Image Restoration to Enhance Perception in Intelligent Transportation Systems[J]. IEEE Transactions on Intelligent Transportation Systems, 2025.
- [54] LIU Y, LI D, FU X, et al. Uhd-processor: Unified uhd image restoration with progressive frequency learning and degradation-aware prompts[C]//Proceedings of the Computer Vision and Pattern Recognition Conference. 2025: 23121-23130.
- [55] WU G, JIANG J, JIANG K, et al. Learning dynamic prompts for all-in-one image restoration[J]. IEEE Transactions on Image Processing, 2025.
- [56] WU G, JIANG J, JIANG K, et al. Beyond degradation redundancy: Contrastive prompt learning for all-in-one image restoration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2025.
- [57] CHEN W T, HUANG Z K, TSAI C C, et al. Learning multiple adverse weather removal via two-stage knowledge learning and multi-contrastive regularization: Toward a unified model[C]//Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022: 17653-17662.
- [58] LI B, LIU X, HU P, et al. All-in-one image restoration for unknown corruption[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 17452-17462.
- [59] HAN Y, TANG J. MCDRNet: a multi-granularity approach for all-in-one image restoration via contrast-guided degradation reconstruction[J]. The Visual Computer, 2026, 42(1): 6.

- [60] CHENG D, LI Y, ZHANG D, et al. Progressive negative enhancing contrastive learning for image dehazing and beyond[J]. IEEE Transactions on Multimedia, 2024, 26: 8783-8798.
- [61] WU G, JIANG J, JIANG K, et al. Learning from history: Task-agnostic model contrastive learning for image restoration[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 38. 2024: 5976-5984.
- [62] WANG L, WU C, WANG L. Dap-led: Learning degradation-aware priors with clip for joint low-light enhancement and deblurring[C]//2025 IEEE International Conference on Robotics and Automation (ICRA). 2025: 15791-15797.
- [63] TOMASI C, MANDUCHI R. Bilateral filtering for gray and color images[C]//Proceedings of IEEE International Conference on Computer Vision: Vol. 0. 1998: 839-846.
- [64] DOSOVITSKIY A, BEYER L, KOLESNIKOV A, et al. An image is worth 16x16 words: Transformers for image recognition at scale[J]. arXiv preprint arXiv:2010.11929, 2020.
- [65] LIU Z, LIN Y, CAO Y, et al. Swin transformer: Hierarchical vision transformer using shifted windows[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 10012-10022.
- [66] LIANG J, CAO J, SUN G, et al. Swinir: Image restoration using swin transformer[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. 2021: 1833-1844.
- [67] ZAMIR S W, ARORA A, KHAN S, et al. Restormer: Efficient transformer for high-resolution image restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 5728-5739.
- [68] WANG Z, CUN X, BAO J, et al. Uformer: A general u-shaped transformer for image restoration[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 17683-17693.
- [69] CHEN X, WANG X, ZHOU J, et al. Activating more pixels in image super-resolution transformer[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 22367-22377.

- [70] MENG X, XIONG Y, SHAO F, et al. A large-scale benchmark data set for evaluating pansharpening performance: Overview and implementation[J]. IEEE Geoscience and Remote Sensing Magazine, 2020, 9(1): 18-52.
- [71] SILBERMAN N, HOIEM D, KOHLI P, et al. Indoor segmentation and support inference from rgb-d images[C]//European Conference on Computer Vision. 2012: 746-760.
- [72] WANG T, ZHANG K, SHAO Z, et al. Gridformer: Residual dense transformer with grid structure for image restoration in adverse weather conditions[J]. International Journal of Computer Vision, 2024: 1-23.
- [73] VALANARASU J M J, YASARLA R, PATEL V M. Transweather: Transformer-based restoration of images degraded by adverse weather conditions[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022: 2353-2363.
- [74] GAO H, YANG J, ZHANG Y, et al. Prompt-based ingredient-oriented all-in-one image restoration[J]. IEEE Transactions on Circuits and Systems for Video Technology, 2024, 34(10): 9458-9471.
- [75] CUI Y, ZAMIR S W, KHAN S, et al. Adair: Adaptive all-in-one image restoration via frequency mining and modulation[C]//13th International Conference on Learning Representations, ICLR 2025. 2025: 57335-57356.
- [76] LU H, YANG Y, HUANG S, et al. AWFLN: An adaptive weighted feature learning network for pansharpening[J]. IEEE Transactions on Geoscience and Remote Sensing, 2023, 61: 1-15.
- [77] JIA Q, WAN X, HEI B, et al. DispNet based stereo matching for planetary scene depth estimation using remote sensing images[C]//2018 10th IAPR Workshop on Pattern Recognition in Remote Sensing. 2018: 1-5.
- [78] JIN Z R, ZHANG T J, JIANG T X, et al. LAGConv: Local-context adaptive convolution kernels with global harmonic bias for pansharpening[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 36. 2022: 1113-1121.

- [79] LI Z, HUANG H, LI Y, et al. M3DNet: A manifold-based discriminant feature learning network for hyperspectral imagery[J]. *Expert Systems with Applications*, 2020, 144: 113089.
- [80] PANG Y, ZHAO X, ZHANG L, et al. Multi-scale interactive network for salient object detection[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2020: 9413-9422.
- [81] LU L, LI W, TAO X, et al. Masa-sr: Matching acceleration and spatial adaptation for reference-based image super-resolution[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2021: 6368-6377.
- [82] LI G, LV J, TIAN Y, et al. Transformer-empowered multi-scale contextual matching and aggregation for multi-contrast MRI super-resolution[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022: 20636-20645.
- [83] WANG X, CHEN X, NI B, et al. Learning continuous depth representation via geometric spatial aggregator[C]//*Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 37*. 2023: 2698-2706.
- [84] ZHONG Z, LIU X, JIANG J, et al. Deep attentional guided image filtering[J]. *IEEE Transactions on Neural Networks and Learning Systems*, 2023, 35(9): 12236-12250.
- [85] ZHONG Z, LIU X, JIANG J, et al. High-resolution depth maps imaging via attention-based hierarchical multi-modal fusion[J]. *IEEE Transactions on Image Processing*, 2021, 31: 648-663.
- [86] ZHAO Z, ZHANG J, XU S, et al. Discrete cosine transform network for guided depth map super-resolution[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 2022: 5697-5707.
- [87] KIM B, PONCE J, HAM B. Deformable kernel networks for joint image filtering[J]. *International Journal of Computer Vision*, 2021, 129(2): 579-600.

致谢

时光荏苒，转眼间硕士研究生阶段的学习与科研生活即将画上句号。回首这段充实而难忘的岁月，心中满怀感恩。

首先，我要向我的导师方发明教授致以最诚挚的感谢。方老师严谨的治学态度、敏锐的学术洞察力和深厚的专业素养，始终是我学习和研究的标杆。从课题的选定、研究方案的设计到论文的撰写与修改，方老师都给予了悉心的指导与耐心的帮助。每当我在研究中遇到困惑与瓶颈时，方老师总能以其丰富的经验为我指明方向，帮助我拨云见日。方老师不仅教会了我如何做学术研究，更教会了我如何以踏实认真的态度面对工作与生活，这些宝贵的品质将使我终身受益。

同时，我要衷心感谢汪婷婷老师在研究生期间对我的关心与指导。汪老师在实验方法、论文写作等方面给予了许多宝贵的建议和细致的帮助，让我在科研道路上少走了很多弯路。汪老师亲切温和的为人处世方式也让我在求学过程中倍感温暖。

感谢实验室的各位同学，感谢你们在学习和生活中给予的陪伴和帮助。与大家一起讨论问题、分享思路的时光，是我研究生生涯中最珍贵的回忆之一。

最后，感谢我的家人一直以来无条件的支持与鼓励。正是你们的理解与付出，让我能够心无旁骛地投入到学业之中。

谨以此文，献给所有关心和帮助过我的人。

攻读硕士学位期间科研情况

论文发表情况

- WANG T, **WANG J**, YAN Q, et al. Task-aware All-in-One Guided Image Super-Resolution[J]. Pattern Recognition, 2026: 11348 (SCI 1 区)

发明专利

- 申请人: **王君**, 方发明, 汪婷婷。《基于多模态提示与自适应路由的一体化引导式图像超分方法》。申请号: 2026100492687